

3DShape2VecSet: 面向神经场与生成扩散模型的三维形状表示

BIAO ZHANG, KAUST, Saudi Arabia

JIAPENG TANG, TU Munich, Germany

MATTHIAS NIEßNER, TU Munich, Germany

PETER WONKA, KAUST, Saudi Arabia




Fig. 1. 左图：形状自动编码结果（从点云进行表面重构）右图：3DShape2VecSet 的各种下游应用（从上到下）：(a) 类别条件生成；(b) 点云条件生成（从部分点云进行形状补全）；(c) 图像条件生成（从单视图图像进行形状重构）；(d) 文本条件生成。

我们提出了 3DShape2VecSet，一种专为生成式扩散模型设计的新型形状表示方法，适用于神经场。该形状表示能够将表面模型或点云形式给出的 3D 形状编码，并以神经场的形式进行表示。此前，神经场的概念已与全局潜在向量、规则网格的潜在向量或不规则网格的潜在向量相结合。我们的新表示方法则在一组向量之上编码神经场。我们借鉴了多种概念，如径向基函数表示以及交叉注意力和自注意力函数，设计了一种特别适合 Transformer 处理的可学习表示。我们的结果表明，在 3D 形状编码和 3D 形状生成式建模任务中，性能得到了提升。我们展示了多种生成应用：无条件生成、类别条件生成、文本条件生成、点云补全以及图像条件生成。代码：<https://1zb.github.io/3DShape2VecSet/>。

Authors' addresses: Biao Zhang, KAUST, Saudi Arabia, biao.zhang@kaust.edu.sa; Jiapeng Tang, TU Munich, Germany, jiapeng.tang@tum.de; Matthias Nießner, TU Munich, Germany, niessner@tum.de; Peter Wonka, KAUST, Saudi Arabia, peter.wonka@kaust.edu.sa.

Additional Key Words and Phrases: 3D Shape Generation, 3D Shape Representation, Diffusion Models, Shape Reconstruction, Generative models

1 引言

生成逼真且多样的 3D 内容的能力有许多潜在应用，包括计算机图形学、游戏和虚拟现实。为此，已经探索了许多生成模型，例如生成对抗网络、变分自编码器、归一化流和自回归模型。最近，扩散模型作为一种最流行的方法出现，在 2D 图像领域取得了出色的结果 [Ho et al. 2020; Rombach et al. 2022]，并显示出优于其他生成方法的优势。例如，可以进行无条件生成 [Karras et al. 2022; Rombach et al. 2022]、文本条件生成 [Rombach

et al. 2022; Saharia et al. 2022] 和生成图像修复 [Lugmayr et al. 2022]。然而，2D 领域的成功尚未在 3D 领域得到匹配。

在本研究中，我们将探讨用于三维形状生成的扩散模型。将二维扩散模型适应于三维场景的一大挑战在于设计一种合适的形状表示。我们工作的核心正是围绕这一形状表示的设计展开，并将详细讨论促成我们所提出表示方法开发的若干设计决策。

与二维图像不同，3D 数据有几种主要的表示方式，例如体素、点云、网格和神经场。总体而言，我们认为基于表面的表示比点云更适合下游应用。在可用的选择中，我们选择基于神经场，因为它们具有许多优势：它们是连续的，表示完整的表面而不仅仅是点样本，并且它们能够将传统数据结构设计与使用神经网络的表示学习进行许多有趣的结合。

两种主要的二维扩散模型方法是使用压缩的潜在空间，例如潜在扩散 [Rombach et al. 2022]，或者使用一系列分辨率逐渐增加的扩散模型，例如 [Ramesh 2022; Saharia et al. 2022]。虽然这两种方法在三维中似乎都可可行，但我们的初步实验表明，使用压缩的潜在空间更为简便。因此，我们采用了潜在扩散方法。

在潜在扩散方法中，一个后续的设计选择是决定使用学成的表示还是手动设计的表示。手动设计的表示，如小波 [Hui et al. 2022]，更易于设计且更轻量，但在许多情况下，学成的表示已显示出优于手动设计的表示。因此，我们选择探索学成的表示。这需要采用两阶段的训练策略。第一阶段是使用自编码器（变分自编码器）将 3D 形状编码到潜在空间中。第二阶段是在学成的潜在空间中训练扩散模型。

在训练扩散模型用于 3D 神经场时，更需要潜在空间中进行生成。首先，扩散模型通常处理固定大小的数据（例如，给定固定分辨率的图像）。其次，神经场是一个连续的实值函数，可以视为无限维的向量。基于这两个原因，我们决定首先找到一种将形状编码到潜在空间的方法（以及一种将潜在向量解码回形状的方法）。

最后，我们必须设计一种合适的学成神经场表示，以在压缩与重构质量之间取得良好的平衡。这种设计通常需要三个组件：一个用于存储潜在信息的空间数据结构、一种空间插值方法以及一个神经网络结构。文献中提出了多种选项，如图 2 所示。早期方法使用单一的全局潜在向量结合 MLP 网络 [Mescheder et al. 2019; Park et al. 2019]。这一概念简单且快速，但通常难以重构高质量的形状。通过使用 3D 规则网格的潜在 [Peng et al. 2020]，结合三线性插值和 MLP，可以获得更好的形状细节。然而，这种表示对于生成式模型来说过大，只能使用非常低分辨率的网格（例如， $8 \times 8 \times 8$ ）。通过引入稀疏性（例如，[Yan et al. 2022; Zhang et al. 2022]），

潜在被排列在不规则网格中。潜在大小大幅减少，但仍有许多改进空间，我们在 3DShape2VecSet 的设计中充分利用了这一点。

3DShape2VecSet 的设计结合了神经场、径向基函数以及注意力层的网络结构的思想。类似于连续函数的径向基函数表示，我们也可以以类似的形式（线性组合）重写现有方法。受 Transformer 网络中交叉注意力的启发 [Vaswani et al. 2017]，我们推导出了所提出的潜在表示，这是一个固定大小的潜在向量集合。我们认为有两个主要原因促成了表示的成功。首先，该表示非常适合与基于 Transformer 的网络一起使用。由于基于 Transformer 的网络通常优于当前的替代方案，我们可以更好地受益于这种网络结构。而不是仅使用 MLPs 来处理潜在信息，我们使用了一个线性层和交叉注意力。其次，该表示不再使用显式设计的位置特征，而是只给网络提供以任何它认为合适的形式编码位置信息的选项。这符合我们倾向于学习到的表示而非手动设计的表示的设计原则。参见 Fig. 2 e) 中的所提出的潜在表示。

利用我们新颖的形状表示方法，能够在学成的 3D 形状潜在空间中训练扩散模型。我们的成果显示，相较于当前最先进技术，形状编码质量与生成质量均得到了提升。尽管使用扩散模型进行 3D 形状生成的先驱工作已展示了无条件 3D 形状生成的能力，我们进一步展示了 3D 扩散模型的多种新颖应用：类别条件生成、文本条件形状生成、单视图图像形状重构，以及部分点云形状重构。

总之，我们的贡献如下：

- (1) 我们提出了一种新的三维形状表示方法。任何形状均可通过固定长度的潜在数组来表示，并借助交叉注意力与线性层处理，从而生成神经场。
- (2) 我们提出了一种新的网络结构，用于处理所提出表示中的形状，其中包括一个利用交叉注意力从大规模点云中聚合信息的构建块。
- (3) 我们提升了三维形状自动编码的技术水平，实现了包含局部细节的高保真重构。
- (4) 我们提出了一种潜在集合扩散框架，该框架在 3D 形状生成领域，通过 FID、KID、FPD 和 KPD 等指标衡量，显著提升了当前的最先进状态。
- (5) 我们展示了面向类别条件生成、文本条件生成、点云补全及图像条件生成的三维形状扩散技术。

2 相关工作

本节简要回顾了采用多种数据表示的 3D 形状学习以及 3D 形状生成式模型的相关文献。




Fig. 2. 连续函数表示。标量用球体表示，而向量用立方体表示。箭头显示了如何计算空间插值。 x_i 和 x 分别是锚点和查询点的坐标。 λ_i 是锚点 x_i 在 (a) 中的 SDF 值。 f_i 是位于 x_i 的关联特征向量，在 (c)(d) 中。查询的 SDF/特征 x 基于 (a)(c)(d) 中的距离函数 $\phi(x, x_i)$ ，而我们提出的潜在集表示 (e) 通过交叉注意力机制利用查询坐标与锚定特征之间的相似度 $\phi(x, f_i)$ 。

表 1. 用于 3D 形状的神经场。我们根据潜在变量的位置对方进行分类。

# Latents	Latent Position	Methods
Single	Global	OccNet [Mescheder et al. 2019]
		DeepSDF [Park et al. 2019]
		IM-Net [Chen and Zhang 2019]
Multiple	Regular Grid	ConvOccNet [Peng et al. 2020]
		IF-Net [Chibane et al. 2020]
		LIG [Jiang et al. 2020]
		DeepLS [Chabra et al. 2020]
		SA-ConvOccNet [Tang et al. 2021]
		NKF [Williams et al. 2022]
Multiple	Irregular Grid	LDIF [Genova et al. 2020]
		Point2Surf [Erler et al. 2020]
		DCC-DIF [Li et al. 2022]
		3DILG [Zhang et al. 2022]
		POCO [Boulch and Marlet 2022]
Multiple	Global	Ours

表 2. 三维形状的生成式模型。

	Generative Models	3D Representation
3D-GAN [Wu et al. 2016]	GAN	Voxels
l-GAN [Achlioptas et al. 2018]	GAN*	Point Clouds
IM-GAN [Chen and Zhang 2019]	GAN*	Fields
PointFlow [Yang et al. 2019]	NF	Point Clouds
GenVoxelNet [Xie et al. 2020]	EBM	Voxels
PointGrow [Sun et al. 2020]	AR	Point Clouds
PolyGen [Nash et al. 2020]	AR	Mesches
GenPointNet [Xie et al. 2021]	EBM	Point Clouds
3DShapeGen [Ibing et al. 2021]	GAN*	Fields
DPM [Luo and Hu 2021]	DM	Point Clouds
PVD [Zhou et al. 2021]	DM	Point Clouds
AutoSDF[Mittal et al. 2022]	AR*	Voxels
CanMap [Cheng et al. 2022]	AR*	Point Clouds
ShapeFormer[Yan et al. 2022]	AR*	Fields
3DILG [Zhang et al. 2022]	AR*	Fields
LION [Zeng et al. 2022]	DM*	Point Clouds
SDF-StyleGAN [Zheng et al. 2022]	GAN	Fields
NeuralWavelet [Hui et al. 2022]	DM*	Fields
TriplaneDiffusion [Shue et al. 2022] [◊]	DM*	Fields
DiffusionSDF [Chou et al. 2022] [◊]	DM*	Fields
Ours	DM*	Fields

* Generative models in latent space.

◊ Works in submission.

2.1 三维形状表示

我们主要讨论以下几种 3D 形状表示方法，包括体素、点云和神经场。

体素。体素网格是从 2D 像素网格扩展而来的，简单地将 3D 形状表示为一个离散的体积网格。由于其规则结构，早期工作利用 3D 转置卷积算子进行形状预测 [Brock et al. 2016; Choy et al. 2016; Dai et al. 2017; Girdhar et al. 2016; Wu et al. 2016, 2015]。基于体素的解码器的一个缺点是，神经网络的计算和内存成本随着网格分辨率的增加而立方级增长。因此，大多数基于体素的方法仅限于低分辨率。基于八叉树的解码器 [Häne et al. 2017; Meagher 1980; Riegler et al. 2017b,a; Tatarchenko et al. 2017; Wang et al. 2017, 2018] 和基于稀疏哈希的解码器 [Dai et al. 2020] 考虑了 3D 空间的稀疏性，缓解了效率问题并支持高分辨率输出。

点云。早期基于神经网络的点云处理工作包括 PointNet [Qi et al. 2017a,b] 和 DGCNN [Wang et al. 2019]。这些工作建立在逐点的全连接层之上。最近，transformer [Vaswani et al. 2017] 被提出用于点云处理，例如 [Guo et al. 2021; Zhang et al. 2022; Zhao et al. 2021]。这些工作受到图

像领域中 Vision Transformers (ViT) [Dosovitskiy et al. 2021] 的启发。点首先被分组为 patch 以形成 token，然后输入到带有自注意力的 transformer 中。在本工作中，我们也引入了一种用于处理点云的网络。在之前工作的基础上，我们将给定的点云压缩为更适合生成式建模的小型表示。

神经场。近期趋势是采用神经场作为三维数据表示。其核心构建模块是一个神经网络，该网络接受三维坐标作为输入，并输出一个标量 [Chen and Zhang 2019; Mescheder et al. 2019; Michalkiewicz et al. 2019; Park et al. 2019] 或一个向量 [Chan et al. 2022; Mildenhall et al. 2020]。通过这个神经网络，三维对象被隐式定义。神经场因其能生成具有任意拓扑结构和无限分辨率的对象而广受欢迎。这些方法也被称为神经隐式表示或基于坐标的网络。针对三维形状建模的神经场，我们可以将方法分为全局方法和局部方法。1) 全局方法使用单一全局潜在向量 [Mescheder et al. 2019; Park et al. 2019] 对形状进行编码。通常，这类方法的容量有限，无法编码形状细节。2) 局部方法则采用局部化的潜在向量，这些向量定义在规则 [Chibane et al. 2020; Jiang et al. 2020; Peng et al. 2020; Tang et al. 2021] 或不规则网格 [Boulch and Marlet 2022; Genova et al. 2020; Li et al. 2022; Zhang et al. 2022] 上的三维位置。相比之下，我们提出了一种潜在表示，其中潜在向量并不关联特定的三维位置。相反，我们学习将形状表示为一组潜在向量列表。参见 Tab. 1。

2.2 生成式模型

在过去的十年中，我们在不同的二维图像生成模型中取得了巨大成功。流行的深度生成方法包括生成对抗网络 (GANs) [Goodfellow et al. 2014]、变分自编码器 (VAEs) [Kingma and Welling 2014]、归一化流 (NFs) [Rezende and Mohamed 2015]、基于能量的模型 [LeCun et al. 2006; Xie et al. 2016]、自回归模型 (ARs) [Esser et al. 2021; Van Den Oord et al. 2017]，以及最近在我们的工作中选择的生成模型——扩散模型 (DMs) [Ho et al. 2020]。

在 3D 领域，GANs 在 3D 生成方面已经非常流行 [Achlioptas et al. 2018; Chen and Zhang 2019; Ibing et al. 2021; Wu et al. 2016; Zheng et al. 2022]，而只有少数工作使用了 NFs [Yang et al. 2019] 和 VAEs [Mo et al. 2019]。许多近期研究采用了 ARs [Cheng et al. 2022; Mittal et al. 2022; Nash et al. 2020; Sun et al. 2020; Yan et al. 2022; Zhang et al. 2022]。与其他生成方法相比，DMs 在 3D 形状方面的应用相对较少。

有几种扩散模型 (DMs) 处理点云数据 [Luo and Hu 2021; Zeng et al. 2022; Zhou et al. 2021]。由于回归坐标的高自由度，通过后处理获得干净的流形表面始终具有挑战性。如前所述，我们相信神经场通常比点

云更适合于 3D 形状生成。结合扩散模型和神经场的领域仍待深入探索。

DreamFusion [Poole et al. 2022] 探索了如何从预训练的 2D 图像扩散模型中提取 3D 信息。最近的 NeuralWavelet [Hui et al. 2022] 首先将形状（表示为带符号距离场）通过小波变换编码到频域，然后在频率系数上训练扩散模型。虽然这种表述很优雅，但生成式模型通常在学成的表示上表现更好。一些同时进行的工作 [Chou et al. 2022; Shue et al. 2022] 在提交中也利用了潜在空间中的扩散模型进行神经场生成。TriplaneDiffusion [Shue et al. 2022] 首先为每个形状训练一个自解码器。DiffusionSDF [Chou et al. 2022] 则基于三平面特征 [Peng et al. 2020] 运行形状自编码器。

三维生成方法概述。我们在 Tab. 2 中列出了几种 3D 生成方法，重点介绍了生成式模型 (GAN、DM、EBM、NF 或 AR) 的选择以及用于表示 3D 形状的数据结构（点云、网格、体素或场）的选择。

3 初步研究

一个注意力层 [Vaswani et al. 2017] 包含三种输入：查询、键和值。查询 $Q = [q_1, q_2, \dots, q_{N_q}] \in \mathbb{R}^{d \times N_q}$ 和键 $K = [k_1, k_2, \dots, k_{N_k}] \in \mathbb{R}^{d \times N_k}$ 首先进行比较以生成系数 $q_j^T k_i / \sqrt{d}$ （这些系数需要使用 softmax 函数进行规范化），

$$A_{i,j} = \frac{q_j^T k_i / \sqrt{d}}{\sum_{i=1}^{N_k} \exp(q_j^T k_i / \sqrt{d})} \quad (1)$$

系数随后用于（线性地）组合值 $V = [v_1, v_2, \dots, v_{N_k}] \in \mathbb{R}^{d \times N_k}$ 。我们可以将注意力层的输出表示如下，

$$\begin{aligned} \text{Attention}(Q, K, V) &= [o_1 \quad o_2 \quad \dots \quad o_{N_q}] \in \mathbb{R}^{d \times N_q} \\ &= \left[\sum_{i=1}^{N_k} A_{i,1} v_i \quad \sum_{i=1}^{N_k} A_{i,2} v_i \quad \dots \quad \sum_{i=1}^{N_k} A_{i,N_q} v_i \right] \end{aligned} \quad (2)$$

交叉注意力。给定两个集合 $A = [a_1, a_2, \dots, a_{N_a}] \in \mathbb{R}^{d_a \times N_a}$ 和 $B = [b_1, b_2, \dots, b_{N_b}] \in \mathbb{R}^{d_b \times N_b}$ ，查询向量 Q 通过一个线性函数 $q(\cdot) : \mathbb{R}^{d_a} \rightarrow \mathbb{R}^d$ 构造，将 A 的元素作为输入。类似地，我们分别用 $k(\cdot) : \mathbb{R}^{d_b} \rightarrow \mathbb{R}^d$ 和 $v(\cdot) : \mathbb{R}^{d_b} \rightarrow \mathbb{R}^d$ 构造 K 和 V 。 $k(\cdot)$ 和 $v(\cdot)$ 的输入均来自 B 。式 (2) 的输出中的每一列可以表示为，

$$o(a_j, B) = \sum_{i=1}^{N_b} v(b_i) \cdot \frac{1}{Z(a_j, B)} \exp(q(a_j)^T k(b_i) / \sqrt{d}), \quad (3)$$

其中 $Z(a_j, B) = \sum_{i=1}^{N_b} \exp(q(a_j)^\top k(b_i)/\sqrt{d})$ 是一个归一化因子。两组之间的交叉注意力算子为，

$$\text{CrossAttn}(A, B) = [\text{o}(a_1, B) \quad \text{o}(a_2, B) \quad \cdots \quad \text{o}(a_{N_a}, B)] \in \mathbb{R}^{N_a} \quad (4)$$

自注意力机制。在自注意力的情况下，我们让这两个集合相同 $A = B$ ，

$$\text{SelfAttn}(A) = \text{CrossAttn}(A, A). \quad (5)$$

4 神经场的潜在表示

我们的表示方法灵感源自径向基函数 (RBFs)。因此，我们将以 RBF 为起点，阐述表面表示的设计思路，并介绍如何结合神经场概念与 Transformer 架构对其进行扩展。利用 RBFs，一个连续函数可通过三维空间中一组带权重的点来表示。

$$\hat{O}_{\text{RBF}}(\mathbf{x}) = \sum_{i=1}^M \lambda_i \cdot \phi(\mathbf{x}, \mathbf{x}_i) \quad (6)$$

其中 $\phi(\mathbf{x}, \mathbf{x}_i)$ 是径向基函数 (RBF)，通常表示两个输入之间的相似度 (或相异度)，

$$\phi(\mathbf{x}, \mathbf{x}_i) = \phi(\|\mathbf{x} - \mathbf{x}_i\|). \quad (7)$$

给定地面实况占用率 x_i ，可以通过求解一个线性方程组来获得 λ_i 的值。通过这种方式，我们可以将连续函数 $O(\cdot)$ 表示为一组包含其对应权重的 M 个点，

$$\{\lambda_i \in \mathbb{R}, \mathbf{x}_i \in \mathbb{R}^3\}_{i=1}^M. \quad (8)$$

然而，为了保留 3D 形状的细节，我们通常需要大量的点 (例如，在 [Carr et al. 2001] 中的 $M = 80,000$)。这种表示无法受益于表示学习的最新进展，也无法与更紧凑的学成表示相竞争。因此，我们希望修改该表示，将其转变为神经场。

一种处理神经场的方法是将每个形状表示为一个分离的神经网络 (使固定大小网络的权重成为形状的代表)，并训练一个扩散过程作为超网络。第二种方法是使用一个共享的编码器-解码器网络来处理所有形状，并将每个形状表示为编码器计算出的潜在表示。我们选择第二种方法，因为它能产生更紧凑的表示，因为它从数据集中所有形状联合学成的，且网络权重本身不计入潜在表示。这样的神经场以坐标元组 $\mathbf{x}$ 和 C 维潜在 $\mathbf{f}$ 作为输入，并输出占用情况，

$$\hat{O}_{\text{NN}}(\mathbf{x}) = \text{NN}(\mathbf{x}, \mathbf{f}), \quad (9)$$

其中 $\text{NN} : \mathbb{R}^3 \times \mathbb{R}^C \rightarrow [0, 1]$ 是一个神经网络。最初的方法是使用单一的全局潜在 $\mathbf{f}$ ，但主要限制在于其编

码形状细节的能力 [Mescheder et al. 2019]。一些后续研究探讨了坐标依赖的潜在 [Chibane et al. 2020; Peng et al. 2020; Sajjadi et al. 2022]，这些研究将传统数据结构 (如规则网格) 与神经场概念相结合。潜在向量被布置在空间数据结构中，然后通过 (三线性) 插值得到坐标依赖的潜在 $\mathbf{f}_x$ 。最近的工作 3DILG [Zhang et al. 2022] 提出了一种用于 3D 形状的稀疏表示，使用在点位置 $\mathbf{x}_i$ 上不规则网格中布置的潜在 $\mathbf{f}_i$ 。最终，通过核回归估计出坐标依赖的潜在 $\mathbf{f}_x$ ，

$$\mathbf{f}_x = \hat{\mathcal{F}}_{\text{KN}}(\mathbf{x}) = \sum_{i=1}^M \mathbf{f}_i \cdot \frac{1}{Z(\mathbf{x}, \{\mathbf{x}_i\}_{i=1}^M)} \phi(\mathbf{x}, \mathbf{x}_i), \quad (10)$$

其中 $Z(\mathbf{x}, \{\mathbf{x}_i\}_{i=1}^M) = \sum_{i=1}^M \phi(\mathbf{x}, \mathbf{x}_i)$ 是一个归一化因子。因此，3D 形状的代表可以写为

$$\{\mathbf{f}_i \in \mathbb{R}^C, \mathbf{x}_i \in \mathbb{R}^3\}_{i=1}^M. \quad (11)$$

随后，应用 $\text{MLP} : \mathbb{R}^C \rightarrow [0, 1]$ 将近似特征 $\hat{\mathcal{F}}_{\text{KN}}(\mathbf{x})$ 投影到占用率上，

$$\hat{O}_{\text{3DILG}}(\mathbf{x}) = \text{MLP}(\hat{\mathcal{F}}_{\text{KN}}(\mathbf{x})). \quad (12)$$

提出具有潜在集合的神经网络。我们最初探索了基于不规则和规则网格、三平面、频率组合以及其他因子表示的多种三维形状表示变体。最终，我们无法在现有不规则网格的基础上取得改进。然而，通过以下改变，我们实现了显著的提升。我们的目标是保留不规则网格的结构和插值，但不显式表示实际的空间位置。我们让网络编码空间信息。这两种表示 (公式 (6) 中的 RBF 和公式 (10) 中的 3DILG) 都由两部分组成，值和相似度。我们保留了插值的结构，但消除了显式的点坐标，并集成了公式 (3) 中的交叉注意力。结果是一个如下的可学习函数逼近器，

$$\hat{\mathcal{F}}(\mathbf{x}) = \sum_{i=1}^M \mathbf{v}(\mathbf{f}_i) \cdot \frac{1}{Z(\mathbf{x}, \{\mathbf{f}_i\}_{i=1}^M)} e^{q(\mathbf{x})^\top k(\mathbf{f}_i)/\sqrt{d}}, \quad (13)$$

其中 $Z(\mathbf{x}, \{\mathbf{f}_i\}_{i=1}^M) = \sum_{i=1}^M e^{q(\mathbf{x})^\top k(\mathbf{f}_i)/\sqrt{d}}$ 是一个归一化因子。类似于公式 12 中的 MLP，我们应用一个全连接层来获得所需的占用值，

$$\hat{O}(\mathbf{x}) = \text{FC}(\hat{\mathcal{F}}(\mathbf{x})). \quad (14)$$

与 3DILG 及所有其他基于坐标-潜在的方法相比，我们摒弃了对坐标集 $\{\mathbf{x}_i\}_{i=1}^M$ 的依赖，新的表示仅包含一组潜在变量，

$$\{\mathbf{f}_i \in \mathbb{R}^C\}_{i=1}^M. \quad (15)$$

我们提出的函数近似器的另一种视角是将其视为查询点 $\mathbf{x}$ 与一组潜在变量之间的交叉注意力。




Fig. 3. 形状自动编码流水线。给定一个 3D 真实表面网格作为输入，我们首先采样一个点云，将其映射到位置嵌入，并通过一个交叉注意力模块将其编码为一组潜在代码（第5.1节）。接下来，我们在潜在空间中进行（可选的）压缩和 KL 正则化，以获得结构化和紧凑的潜在形状表示（第5.2节）。最后，执行自注意力以聚合和交换潜在集合中的信息。并设计了一个交叉注意力模块来计算查询点的插值权重。插值后的特征向量被输入到一个全连接层中进行占用预测（第5.3节）。




Fig. 4. 两种点云编码方式。(a) 使用可学习的查询集；(b) 使用输入点嵌入的下采样版本作为查询集。

5 形状表示学习的网络结构

在本节中，我们将讨论如何基于 Sec. 4 中提出的潜在表示设计一个变分自编码器。该架构包含以下三个部分：一个 3D 形状编码器、KL 正则化块和一个 3D 形状解码器。

5.1 形状编码

我们对 3D 形状数据集中的 3D 输入形状表面进行采样。这为每个形状生成一个大小为 N 的点云， $\{x_i \in \mathbb{R}^3\}_{i=1}^N$ 或以矩阵形式 $X \in \mathbb{R}^{3 \times N}$ 表示。尽管论文中使用的数据集最初将形状表示为三角网格，但我们的框架直接兼容其他表面表示，如扫描点云、样条曲面或隐式曲面。

为了学习以 Eq. (15) 形式的表示，首要挑战是将可能庞大的点云 $\{x_i\}_{i=1}^N$ 中包含的信息聚合为一组较小的潜在向量 $\{f_i\}_{i=1}^M$ 。为此，我们设计了一个集合到集合的网络。

以往研究中，针对这一问题的一个普遍解决方案是将大规模点云分割为较小的一组补丁，并为每个补

丁学习一个潜在向量。尽管这一方法在许多网络中已被深入探讨并成为标准组件，但我们发现了一种更为有效的方式来聚合大规模点云中的特征，这种方式与 Transformer 架构更为契合。为此，我们探讨了两种方案。

一种方法是定义一个可学习的查询集。受 DETR [Carion et al. 2020] 和 Perceiver [Jaegle et al. 2021] 的启发，我们使用交叉注意力来编码 X ，

$$\text{Enc}_{\text{learnable}}(X) = \text{CrossAttn}(L, \text{PosEmb}(X)) \in \mathbb{R}^{C \times M}, \quad (16)$$

其中 $L \in \mathbb{R}^{C \times M}$ 是一个可学习的查询集，每个条目都是 C 维的，而 $\text{PosEmb} : \mathbb{R}^3 \rightarrow \mathbb{R}^C$ 是一个列向的位置嵌入函数。

另一种方法是利用点云本身。我们首先对点云 X 进行子采样，得到一个通过最远点采样得到的较小点云， $X_0 = \text{FPS}(X) \in \mathbb{R}^{3 \times M}$ 。交叉注意力应用于 X_0 和 X ，

$$\text{Enc}_{\text{points}}(X) = \text{CrossAttn}(\text{PosEmb}(X_0), \text{PosEmb}(X)), \quad (17)$$

这也可以被视为一种“部分”自注意力机制。参见 Fig. 4 以了解这两种设计选择的图示。直观上，数值 M 影响重构性能： M 越大，重构效果越好。然而，由于 Transformer 架构， M 会显著影响训练时间，因此不宜设置过大。在我们的最终模型中，潜在变量数量 M 被设定为 512，而通道数 C 为 512，以在重构质量与训练时间之间取得平衡。

5.2 KL 正则化块

潜在扩散 [Rombach et al. 2022] 提出使用变分自编码器 (VAE) [Kingma and Welling 2014] 来压缩图像。我们将这一设计理念应用于我们的 3D 形状表示，并通过 KL 散度对潜在表示进行正则化。需要注意的是，KL 正则化是可选的，仅在第二阶段的扩散模型训练中必要。如果我们仅需一种从点云进行表面重构的方法，则无需 KL 正则化。

我们首先通过两个网络分支分别将潜在变量线性投影为均值和方差，

$$\begin{aligned} \text{FC}_\mu(f_i) &= (\mu_{i,j})_{j \in [1, 2, \dots, C_0]} \\ \text{FC}_\sigma(f_i) &= (\log \sigma_{i,j}^2)_{j \in [1, 2, \dots, C_0]} \end{aligned} \quad (18)$$

其中 $\text{FC}_\mu : \mathbb{R}^C \rightarrow \mathbb{R}^{C_0}$ 和 $\text{FC}_\sigma : \mathbb{R}^C \rightarrow \mathbb{R}^{C_0}$ 是两个线性投影层。我们使用不同大小的输出通道 C_0 ，其中 $C_0 \ll C$ 。这种压缩使我们能够在总大小为 $M \cdot C_0 \ll M \cdot C$ 的较小潜在空间上训练扩散模型。我们可以正式地写出 VAE 的瓶颈， $\forall i \in [1, 2, \dots, M], j \in [1, 2, \dots, C_0]$,

$$z_{i,j} = \mu_{i,j} + \sigma_{i,j} \cdot \epsilon, \quad (19)$$

其中 $\epsilon \sim \mathcal{N}(0, 1)$ 。KL 正则化可以表示为，

$$\mathcal{L}_{\text{reg}}(\{f_i\}_{i=1}^M) = \frac{1}{M \cdot C_0} \sum_{i=1}^M \sum_{j=1}^{C_0} \frac{1}{2} (\mu_{i,j}^2 + \sigma_{i,j}^2 - \log \sigma_{i,j}^2). \quad (20)$$

在实践中，我们将 KL 损失的权重设为 0.001，并在 Sec. 8.1 中报告了不同 C_0 值下的性能。我们推荐的设置是 $C_0 = 32$ 。

5.3 形状解码

为了增强网络的表达能力，我们在两部分之间加入了一个潜在学习网络。鉴于我们的潜在变量是一组向量，在此处采用 Transformer 网络显得自然而然。因此，所提出的网络由一系列自注意力块构成，

$$\{f_i\}_{i=1}^M \leftarrow \text{SelfAttn}^{(l)}(\{f_i\}_{i=1}^M), \quad \text{for } i = 1, \dots, L. \quad (21)$$

这里的 $\text{SelfAttn}(\cdot)$ 带有上标 (l) 表示第 l 个块。使用 Eq. (16) 或 Eq. (17) 获得的潜在变量 $\{f_i\}_{i=1}^M$ 被输入到自注意力块中。给定一个查询 x ，相应的潜在变量通过 Eq. (13) 进行插值，并通过全连接层获得占用情况，如 Eq. (14) 所示。

损失。我们优化了近似函数与真实指示函数之间的二元交叉熵损失，如先前工作 [Mescheder et al. 2019] 中所述。

$$\mathcal{L}_{\text{recon}}(\{f_i\}_{i=1}^M, \mathcal{O}) = \mathbb{E}_{x \in \mathbb{R}^3} [\text{BCE}(\hat{\mathcal{O}}(x), \mathcal{O}(x))]. \quad (22)$$




Fig. 5. **KL 正则化**。给定从第 5.1 节形状编码中获得的潜在变量集 $\{f_i \in \mathbb{R}^C\}_{i=1}^M$ ，我们采用两个线性投影层 $\text{FC}_\mu, \text{FC}_\sigma$ 来预测低维潜在空间的均值和方差，其中应用了 VAE 训练中常用的 KL 正则化以约束特征多样性。随后，通过重参数化采样得到大小为 $M \cdot C_0 \ll M \cdot C$ 的较小潜在变量 $\{z_i \in \mathbb{R}^{C_0}\}$ 。最后，压缩后的潜在变量通过 FC_{up} 映射回原始空间，以便在第 5.3 节中进行形状解码时获得更高的维度。




Fig. 6. **潜在集合扩散模型**。该扩散模型操作于一组正则化潜在在向量形式表示的压缩 3D 形状上 $\{z_i\}_{i=1}^M$ 。




Fig. 7. **降噪网络**。我们的降噪网络由多个降噪层组成（图中一个方框表示一层）。无条件生成的降噪层包含两个顺序的自注意力块。条件生成的降噪层包含一个自注意力块和一个交叉注意力块。交叉注意力用于注入条件信息，如类别、图像或部分点云。

表面重构。我们在分辨率为 128^3 的网格中对查询点进行采样。最终表面通过 Marching Cubes [Lorensen and Cline 1987] 进行重建。

6 形状生成

我们提出的扩散模型结合了潜在扩散（压缩潜在空间的概念）、EDM [Karras et al. 2022]（大部分训练细节）

以及我们的形状表示设计（架构基于注意力和自注意力而非卷积）的设计决策。

我们在潜在空间中训练扩散模型，即在 Eq. (19) 中的瓶颈层。遵循 EDM [Karras et al. 2022] 中的扩散公式，我们的降噪目标为

$$\mathbb{E}_{\mathbf{n}_i \sim \mathcal{N}(0, \sigma^2 \mathbf{I})} \frac{1}{M} \sum_{i=1}^M \left\| \text{Denoiser}(\{\mathbf{z}_i + \mathbf{n}_i\}_{i=1}^M, \sigma, \mathbf{C})_i - \mathbf{z}_i \right\|_2^2, \quad (23)$$

其中 $\text{Denoiser}(\cdot, \cdot, \cdot)$ 是我们的降噪神经网络， σ 是噪声水平， $\mathbf{C}$ 是可选的附加信息（例如，类别、图像、部分点云和文本）。我们用下标 i 表示 $\mathbf{z}_i + \mathbf{n}_i$ 的相应输出，即 $\text{Denoiser}(\cdot, \cdot, \cdot)_i$ 。我们应最小化每个噪声水平 σ 的损失。采样通过求解常微分/随机微分方程 (ODE/SDE) 完成。参见 Fig. 6 以获取图示，以及 EDM [Karras et al. 2022] 以获取关于正向（训练）和反向（采样）过程的详细描述。

函数 $\text{Denoiser}(\cdot, \cdot, \cdot)$ 是一个集合降噪网络（集合到集合函数）。该网络可以轻松地通过自注意力 Transformer 进行建模。每一层由两个注意力块组成。第一个是自注意力块，用于对潜在集合进行注意力学习。第二个块用于注入条件信息 $\mathbf{C}$ (Fig. 7(b))，如先前工作 [Rom-bach et al. 2022] 中所述。对于简单的信息（如类别）， $\mathbf{C}$ 是一个可学习的嵌入向量（例如，55 个类别对应 55 个不同的嵌入向量）。对于单视图图像，我们使用 ResNet-18 [He et al. 2016] 作为上下文编码器，提取全局特征向量作为条件 $\mathbf{C}$ 。对于文本条件，我们使用 BERT [Devlin et al. 2018] 学习一个全局特征向量作为 $\mathbf{C}$ 。对于部分点云，我们使用第 5.1 节中引入的形状编码器，获取一组潜在嵌入作为 $\mathbf{C}$ 。在无条件生成的情况下，交叉注意力退化为自注意力 (Fig. 7(a))。

7 实验设置

我们采用 ShapeNet-v2 [Chang et al. 2015] 数据集作为基准，该数据集包含 55 类人造物体。我们使用 [Zhang et al. 2022] 中的训练/验证划分。按照 [Mescheder et al. 2019] 的方法对形状进行预处理。首先将每个形状转换为水密网格，然后规范化为其边界框，并从中进一步采样出大小为 500,000 的稠密表面点云。为了学习神经场，我们在三维空间中随机采样 500,000 个带有占据信息的点，并在近表面区域采样 500,000 个带有占据信息的点。对于单视角物体重构，我们使用 3D-R2N2 [Choy et al. 2016] 提供的二维渲染数据集，其中每个形状从 24 个随机视角渲染为大小为 224×224 的 RGB 图像。针对文本驱动的形状生成，我们采用 ShapeGlot [Achlioptas et al. 2019] 的文本提示。在形状补全训练的数据预处理中，我们通过采样点云片段来创建部分点云。

7.1 基准线

在形状自动编码方面，我们针对点云隐式表面重构的先进方法进行了实验。我们采用 OccNet [Mescheder et al. 2019]、ConvOccNet [Peng et al. 2020]、IF-Net [Chibane et al. 2020] 和 3DILG [Zhang et al. 2022] 作为基准。OccNet 是首个从单一全局潜在向量学习神经场的工作。ConvOccNet 和 IF-Net 基于规则网格排列的潜在向量学习局部神经场，而 3DILG 则使用不规则网格上的潜在向量。

在 3D 形状生成领域，我们对比了最新的先进生成式模型，包括 PVD [Zhou et al. 2021]、3DILG [Zhang et al. 2022] 和 NeuralWavelet [Hui et al. 2022]。PVD 是一种用于 3D 点云生成的扩散模型，而 3DILG 则采用了自回归模型。NeuralWavelet 则在形状的频率域中应用了扩散模型。

7.2 评估指标

为了评估点云形状自动编码的重构准确率，我们采用 Chamfer 距离、体积交并比 (IoU) 和 F 分数作为主要评价指标。IoU 基于在三维空间中采样的 50k 个查询点的占用预测进行计算。Chamfer 距离和 F 分数分别在重构表面和真实表面上采样大小为 50k 的点云之间计算。对于 IoU 和 F 分数，数值越高越好，而对于 Chamfer 距离，数值越低越好。

为了衡量无条件与条件形状生成的网格质量，我们遵循 [Ibing et al. 2021; Shue et al. 2022; Zhang et al. 2022]，将常用于评估图像生成模型的 Fréchet Inception Distance (FID) 和 Kernel Inception Distance (KID) 调整应用于 3D 形状的渲染图像。为计算渲染图像的 FID 和 KID，我们从 10 个视角渲染每个形状。这些指标被命名为 **Rendering-FID** 和 **Rendering-KID**。

渲染-FID 被定义为，

$$\text{Rendering-FID} = \|\mu_g - \mu_r\| + \text{Tr} \left(\Sigma_g + \Sigma_r - 2(\Sigma_g \Sigma_r)^{1/2} \right) \quad (24)$$

其中 g 和 r 分别表示生成的数据集和训练数据集。 μ 和 Σ 是由 Inception 网络提取的特征分布的统计均值和协方差矩阵。

渲染-KID 被定义为，

$$\text{Rendering-KID} = \text{MMD} \left(\frac{1}{|\mathcal{R}|} \sum_{\mathbf{x} \in \mathcal{R}} \max_{\mathbf{y} \in \mathcal{G}} D(\mathbf{x}, \mathbf{y}) \right)^2 \quad (25)$$

其中 $D(\mathbf{x}, \mathbf{y})$ 是用于评估两个样本相似度的多项式核函数， $\mathcal{G}$ 和 $\mathcal{R}$ 分别是生成集和参考集的特征分布。函数 $\text{MMD}(\cdot)$ 是最大平均偏差。然而，基于渲染的 FID 和 KID 本质上是为了从 2D 图像理解 3D 形状而设计的。因此，它们存在无法准确理解 3D 世界中形状构

表 3. ShapeNet 上的形状自动编码（点云表面重构）。我们展示了所有 55 个类别的平均指标以及 7 个最大类别的单独指标。我们与现有的代表性方法进行了比较，包括 OccNet（全局潜在）、ConvOccNet（局部潜在网格）、IF-Net（多尺度局部潜在网格）和 3DILG（不规则潜在网格）。对于我们的方法，我们展示了两种不同的设计。Learned Queries 列显示了使用 Eq. (16) 的结果，而 Point Queries 列表示我们使用子采样点集作为 Eq. (17) 中的查询。Point Queries 的结果通常优于 Learned Queries。这是预期的，因为依赖于输入的查询（Point Queries）比固定查询（Learned Queries）更好。

		OccNet	ConvOccNet	IF-Net	3DILG	Ours	
						Learned Queries	Point Queries
IoU ↑	table	0.823	0.847	0.901	0.963	0.965	0.971
	car	0.911	0.921	0.952	0.961	0.966	0.969
	chair	0.803	0.856	0.927	0.950	0.957	0.964
	airplane	0.835	0.881	0.937	0.952	0.962	0.969
	sofa	0.894	0.930	0.960	0.975	0.975	0.982
	rifle	0.755	0.871	0.914	0.938	0.947	0.960
	lamp	0.735	0.859	0.914	0.926	0.931	0.956
	mean (selected)	0.822	0.881	0.929	0.952	0.957	0.967
	mean (all)	0.825	0.888	0.934	0.953	0.955	0.965
Chamfer ↓	table	0.041	0.036	0.029	0.026	0.026	0.026
	car	0.082	0.083	0.067	0.066	0.062	0.062
	chair	0.058	0.044	0.031	0.029	0.028	0.027
	airplane	0.037	0.028	0.020	0.019	0.018	0.017
	sofa	0.051	0.042	0.032	0.030	0.030	0.029
	rifle	0.046	0.025	0.018	0.017	0.016	0.014
	lamp	0.090	0.050	0.038	0.036	0.035	0.032
	mean (selected)	0.058	0.040	0.034	0.032	0.031	0.030
	mean (all)	0.072	0.052	0.041	0.040	0.039	0.038
F-Score ↑	table	0.961	0.982	0.998	0.999	0.999	0.999
	car	0.830	0.852	0.888	0.892	0.898	0.899
	chair	0.890	0.943	0.990	0.992	0.994	0.997
	airplane	0.948	0.982	0.994	0.993	0.994	0.995
	sofa	0.918	0.967	0.988	0.986	0.986	0.990
	rifle	0.922	0.987	0.998	0.997	0.998	0.999
	lamp	0.820	0.945	0.970	0.971	0.970	0.975
	mean (selected)	0.898	0.951	0.975	0.976	0.977	0.979
	mean (all)	0.858	0.933	0.967	0.966	0.966	0.970

成的内在问题。为了弥补这些缺陷，我们还将 FID 和 KID 直接应用于 3D 形状。对于每个生成或真实形状，我们从表面网格中采样 4096 个点（带法线），然后将它们输入预训练的 PointNet++ [Qi et al. 2017b] 以提取一个全局潜在向量，表示 3D 形状的全局结构。PointNet++ 首先在 ShapeNet-55 上进行形状分类的预训练。由于我们使用点云，我们将 3D 形状的 FID 和 KID 称为 Fréchet PointNet++ 距离 (FPD) 和 Kernel PointNet++ 距离 (KPD)。这两个指标的定义与 Eq. (24) 和 Eq. (25) 类似，只是特征是从 PointNet++ 网络中提取的。

7.3 实施

对于形状编码器，我们使用大小为 2048 的点云作为输入。在每次迭代中，我们分别从包围盒 $[-1, 1]^3$ 中采样 1024 个查询点，并从近表面区域采样另外 1024 个点用于占据值预测。形状编码器在 8 个 A100 上进行训练，批量大小为 512，训练 $T = 1,600$ 轮次。学习率在前 $t_0 = 80$ 轮次中线性增加至 $lr_{\max} = 5e - 5$ ，随后使用余弦衰减计划 $lr_{\max} * 0.5^{1 + \cos(\frac{t-t_0}{T-t_0})}$ 逐渐降低，直至达到最小值 $1e - 6$ 。

扩散模型在 4 个 A100 上进行训练，批量大小为 256，训练 $T = 8,000$ 轮次。学习率在前 $t_0 = 800$ 轮次中线性增加至 $lr_{\max} = 1e - 4$ ，随后使用上述衰减计划逐渐降低，直至达到 $1e - 6$ 。




Fig. 8. 形状自动编码结果的可视化（基于 ShapeNet 点云的表面重构）。




Fig. 9. 无条件生成。所有 Model 均在完整的 ShapeNet 上进行训练。

我们使用 EDM [Karras et al. 2022] 的默认超参数设置。在采样过程中，我们仅通过 18 次降噪步骤获得最终的潜在集。

8 结果

我们展示了多项应用的结果：1) 形状自动编码，2) 无条件生成，3) 类别条件生成，4) 文本条件生成，5) 形状补全，6) 图像条件生成。最后，我们进行了形状新颖性分析，以验证我们并未对数据集过拟合。

8.1 形状自动编码

我们在 Tab. 3 中展示了未包含 KL 块的确定性自编码器的定量结果，具体如第 5.2 节所述。特别是，我们展示了最大 7 个类别以及各类别平均结果。还研究了 Sec. 5.1 中描述的两形状编码设计选择。在所有类别中，使用子采样点云作为查询的情况优于可学习查询。因此，我们在后续实验中采用了子采样点云。重构结果的可视化可在 Fig. 8 中找到。我们可视化了一些数据集中（测试集）极其复杂的形状，这些形状通常包含一些薄结构。尽管如此，我们的方法依然表现良好。

我们的方法与竞争对手 3DILG 均以 Transformer 为核心架构，但本质上有显著差异。1) 在编码阶段，3DILG 采用 KNN 聚合局部信息，而我们则运用交叉注意力机制。KNN 依据空间相似性（距离）手动选择邻近点，而交叉注意力则动态学习相似性。2) 3DILG 采用一组点及每点一个潜在表示，而我们的表示仅包含一组潜在变量。这一简化使得第二阶段的生成式模型训练更为便捷。3) 在解码方面，3DILG 实施空间插

值，而我们则在特征空间进行插值。所用的交叉注意力可视作可学习的插值方法，赋予我们更大的灵活性。

重构的数值结果意义重大。对于 IoU 和 F1 这两个指标，其最大可达到值为 1。改进的衡量标准在于我们距离 1 有多近。可视化展示同样突显了这一进步。

关于潜在变量数量的消融研究。· 数字 M 是网络中使用的潜在向量数量。直观上，较大的 M 会带来更好的重构效果。我们在 Tab. 4 中展示了 M 的结果。因此，在所有实验中， M 被设置为 512。由于计算时间的限制，我们无法处理更大的 M 。

KL 块的消融研究。· 我们描述了在 Sec. 5.2 中引入的 KL 块，它带来了额外的压缩效果。此外，该块将确定性形状编码转变为变分自编码器。引入的超参数是 C_0 。较小的 C_0 会导致更高的压缩率。 C_0 的选择在 Tab. 5 中进行了消融实验。显然，较大的 C_0 会带来更好的结果。 $C_0 = 8, 16, 32, 64$ 的重构结果非常接近。然而，它们在第二阶段差异显著，因为较大的潜在大小可能会使扩散模型的训练更加困难。这一结果对我们的模型非常鼓舞人心，因为它表明在 KL 块中积极增加压缩并不会过多降低重构性能。我们还可以看到，通过减小 C_0 来使用 KL 块进行压缩，比使用更少的潜在向量 M 进行压缩要好得多。

8.2 无条件形状生成

与表层生成技术的对比。· 我们使用 Tab. 6 中提出的指标评估了无条件形状生成任务。同时，我们将我们的方法与 [Zhang et al. 2022] 中提出的基准方法进行




Fig. 10. 类别条件生成。从上到下，我们展示了基于类别（飞机、椅子、桌子）的条件生成结果。

了比较。该方法被称为 Grid- 8^3 ，因为其潜在网格大小为 8^3 ，这与 AutoSDF [Mittal et al. 2022] 中的设置完全相同。表中还展示了不同 C_0 的结果。在所有指标中，当 $C_0 = 32$ 时，我们的结果最佳。而当 $C_0 = 64$ 时，结果变差。这也符合我们的猜想，即更大的潜在大小会使训练变得更加困难。

与点云生成的对比。此外，我们将我们的方法与 PVD [Zhou et al. 2021] 进行比较，PVD 是一种点云扩散方法。我们使用官方发布的代码在我们的预处理数据集和划分上重新训练 PVD。我们采用与之前相同的评估协议，但有一个主要区别。由于 PVD 只能生成没有法线的点云，我们使用另一个预训练的 PointNet++ (不带法线) 作为特征提取器来计算 Surface-FPD 和 Surface-KPD。Tab. 7 显示我们可以大幅超越 PVD。此

表 4. 消融实验对于不同的潜在数 M 对于形状自动编码

	$M = 512$	$M = 256$	$M = 128$	$M = 64$
IoU $\uparrow$	0.965	0.956	0.940	0.916
Chamfer $\downarrow$	0.038	0.039	0.043	0.049
F-Score $\uparrow$	0.970	0.965	0.953	0.929

表 5. 消融实验对于不同数量的通道 C_0 对于形状（变分）自动编码。

	$C_0 = 1$	$C_0 = 2$	$C_0 = 4$	$C_0 = 8$	$C_0 = 16$	$C_0 = 32$	$C_0 = 64$
IoU $\uparrow$	0.727	0.816	0.957	0.960	0.962	0.963	0.964
Chamfer $\downarrow$	0.133	0.087	0.038	0.038	0.038	0.038	0.038
F-Score $\uparrow$	0.703	0.815	0.967	0.967	0.970	0.969	0.970

外，我们还展示了在渲染图像上计算的指标。生成结果的可视化可以在 Fig. 9 中找到。

8.3 类别条件生成

我们使用我们的方法训练了一个类别条件生成模型。我们在 Tab. 8 中对我们的模型进行了评估。需要注意的是，竞争对手方法 NeuralWavelet [Hui et al. 2022] 为每个类别单独训练模型；因此，NeuralWavelet 并不是一个真正的类别条件模型。我们还在 Fig. 10 中可视化了一些结果（飞机、椅子和桌子）。我们的训练更具挑战性，因为我们在一个规模大一个数量级的数据集上进行训练，并且我们为所有类别联合训练。虽然 NeuralWavelet 已经取得了不错的结果，但联合训练对于许多后续应用是必要且有益的。

此外，我们在 Tab. 9 中展示了评估指标和更多竞争方法。首先，我们使用准确率和召回率 (P&R) [Sajjadi et al. 2018] 分别量化生成的样本与训练样本的相似百分比以及能够生成的训练数据百分比。3DILG、NeuralWavelet 和我们的方法都能实现较高的准确率，这意味着它们能够生成与训练样本相似的形状。然而，我们的方法还显示出显著更好的召回率，这意味着我们的方法能够生成更高比例的训练数据。对于 3DShapeGen 和 AutoSDF，与其他方法相比，其准确率和召回率都较低。其次，我们展示了基于点云距离 (CD 和 EMD) [Achlioptas et al. 2018] 的其他指标。MMD 越小越好，COV 越大越好。这些指标通常用于评估点云生成。

8.4 基于文本条件的生成

我们的文本条件生成模型的结果可在 Fig. 11 中找到。由于该模型是一个概率模型，我们可以根据文本提示生成形状样本。结果非常令人鼓舞，这构成了使用扩散模型进行文本条件三维形状生成的首次展示。据我们所知，在提交本工作时，尚未有已发表的竞争方法。

8.5 概率形状补全

我们还通过使用部分点云作为条件输入，扩展了用于概率形状补全的扩散模型。与 ShapeFormer [Yan et al. 2022] 的比较如图 Fig. 12 所示。可以看出，我们的潜在




Fig. 11. 文本条件生成。对于每个文本提示，我们生成 3 个形状。我们的结果（右）与 AutoSDF（左）进行了比较。

集扩散能够预测更精确的补全结果，并且我们还能够实现更多样化的生成。

8.6 图像引导的形状生成。

我们还提供了在单视图 3D 物体重构任务上的比较，如图 Fig. 13 所示。与包括 OccNet [Mescheder et al. 2019] 和 IM-Net [Chen and Zhang 2019] 在内的其他确定性方法相比，我们的潜在集扩散不仅能够重构出更精确的表面细节（例如背面的长杆和微小孔洞），还支持多模态预测，这是处理严重遮挡时所需的特性。

8.7 形状新颖性分析

我们通过形状检索来证明我们并未仅仅对训练集进行过拟合。给定一个生成的形状，我们测量其与训练集中形状之间的 Chamfer 距离。检索到的形状可视化结果可在 Fig. 14 中找到。显然，该模型能够合成具有真实结构的新形状。

表 6. 无条件生成在完整 ShapeNet 上。

	Grid-8 ³	3DILG	Ours				PVD	Ours
			$C_0 = 8$	$C_0 = 16$	$C_0 = 32$	$C_0 = 64$		
Surface-FPD ↓	4.03	1.89	2.71	1.87	0.76	Surface-FPD ↓	2.33	0.63
Surface-KPD ($\times 10^3$) ↓	6.15	2.17	3.48	2.42	0.66	Surface-KPD ($\times 10^3$) ↓	2.65	0.53
Rendering-FID ↓	32.78	24.83	28.25	27.26	17.08	Rendering-FID ↓	270.64	17.08
Rendering-KID ($\times 10^3$) ↓	14.12	10.51	14.60	19.37	6.75	Rendering-KID ($\times 10^3$) ↓	281.54	6.75

表 7. 无条件生成在完整 ShapeNet 上。

表 8. 类别条件生成。NW 是 NeuralWavelet 的缩写。短横线 “-” 表示 NeuralWavelet 方法未发布在这些类别上训练的模型。

	airplane			chair			table			car			sofa		
	3DILG	NW	Ours	3DILG	NW	Ours	3DILG	NW	Ours	3DILG	NW	Ours	3DILG	NW	Ours
Surface-FID	0.71	0.38	0.62	0.96	1.14	0.76	2.10	1.12	1.19	2.93	-	2.04	1.83	-	0.7
Surface-KID ($\times 10^3$)	0.81	0.53	0.83	1.21	1.50	0.70	3.84	1.55	1.87	7.35	-	3.90	3.36	-	0.7

表 9. 类别条件生成 II. 我们展示了针对类别条件生成的额外指标和额外方法的结果。

	chair					table				
	3DILG	3DShapeGen	AutoSDF	NW	Ours	3DILG	3DShapeGen	AutoSDF	NW	Ours
Precision ↑	0.87	0.56	0.42	0.89	0.86	0.85	0.64	0.64	0.83	0.83
Recall ↑	0.65	0.45	0.23	0.57	0.86	0.59	0.52	0.69	0.68	0.89
MMD-CD ($\times 10^2$) ↓	1.78	2.14	7.27	2.14	1.78	2.85	2.65	2.77	2.68	2.38
MMD-EMD ($\times 10^2$) ↓	9.43	10.55	19.57	11.15	9.41	11.02	9.53	9.63	9.60	8.81
COV-CD ($\times 10^2$) ↑	31.95	28.01	6.31	29.19	37.48	18.54	23.61	21.55	21.71	25.83
COV-EMD ($\times 10^2$) ↑	36.29	36.69	18.34	34.91	45.36	27.73	43.26	29.16	30.74	43.58




Fig. 12. 点云条件生成。我们展示了给定部分点云的三个生成结果。真实点云和用作条件的部分点云如左图所示。我们将我们的结果（右图）与 ShapeFormer（中图）进行了比较。




Fig. 13. 图像条件生成。在左侧列中，我们展示了条件图像。在中间列中，我们展示了 IM-Net 和 OccNet 方法得到的结果。我们的生成结果展示在右侧。

8.8 局限性

尽管我们的方法在多种任务上展现了令人信服的结果，但我们的设计选择也存在一些值得讨论的不足之处。



Fig. 14. 形状生成新颖性。对于生成的形状，我们从训练集中检索出最相似的一个形状。相似度通过采样表面点云的 Chamfer 距离来衡量。在每一对中，我们展示了检索到的形状（左）和生成的形状（右）。生成的形状来自我们的类别条件生成结果。

例如，我们采用了分两阶段的 Training 策略。虽然这提升了生成质量，但第一阶段的 Training 比依赖手工设计的 Features（如小波 [Hui et al. 2022]）更为耗时。此外，如果所考虑的形态数据发生变化，第一阶段可能需要进行重新 Training，而对于第二阶段——我们扩散架构的核心——Training 时间也相对较长。总体而言，我们相信在加速 Training 方面，尤其是在扩散模型的背景下，未来研究有着巨大的潜力。

9 结论

我们推出了 3DShape2VecSet，这是一种专为生成式扩散模型定制的新型形状表示方法，适用于神经场。为此，我们融合了径向基函数、先前的神经场架构、变分自编码以及交叉注意力和自注意力的理念，设计了一种可学习的表示。我们的形状表示能够处理多种输入，包括三角网格和点云，并将 3D 形状编码为基于一组潜在向量的神经场。因此，我们的方法在 3D 形状编码及生成式建模任务中展现了更优的性能，涵盖无条件生成、类别条件生成、文本条件生成、点云补全以及图像条件生成等多个方面。

在未来的工作中，我们看到了诸多令人振奋的可能性。最为关键的是，我们坚信我们的模型在点云与形状处理的多项任务中，进一步推动了技术前沿的发展。特别地，我们计划采用 3DShape2VecSet 的网络结构，以解决从扫描点云进行表面重构的难题。此外，我们预见该技术在内容创作任务中的广泛应用，例如生成带有材质属性的纹理化 3D 模型。最后，我们期望探索利用预训练扩散模型进行提示到提示的形状编辑与操控任务，借鉴图像扩散模型领域的最新进展。

ACKNOWLEDGMENTS

我们谨此感谢 Anna Fröhstück 在图表制作和视频配音方面提供的帮助。本项工作得到了 SDAIA-KAUST 数据科学与人工智能卓越中心 (SDAIA-KAUST AI) 以及 ERC 启动基金 Scan2CAD (804724) 的支持。

REFERENCES

- Panos Achlioptas, Olga Diamanti, Ioannis Mitliagkas, and Leonidas Guibas. 2018. Learning representations and generative models for 3d point clouds. In *International conference on machine learning*. PMLR, 40–49.
- Panos Achlioptas, Judy Fan, Robert Hawkins, Noah Goodman, and Leonidas J Guibas. 2019. ShapeGlot: Learning language for shape differentiation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 8938–8947.
- Alexandre Boulch and Renaud Marlet. 2022. Poco: Point convolution for surface reconstruction. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 6302–6314.
- Andrew Brock, Theodore Lim, James M Ritchie, and Nick Weston. 2016. Generative and discriminative voxel modeling with convolutional neural networks. *arXiv preprint arXiv:1608.04236* (2016).
- Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. 2020. End-to-end object detection with transformers. In *European conference on computer vision*. Springer, 213–229.
- Jonathan C Carr, Richard K Beatson, Jon B Cherrie, Tim J Mitchell, W Richard Fright, Bruce C McCallum, and Tim R Evans. 2001. Reconstruction and representation of 3D objects with radial basis functions. In *Proceedings of the 28th annual conference on Computer graphics and interactive techniques*. 67–76.
- Rohan Chabra, Jan E Lenssen, Eddy Ilg, Tanner Schmidt, Julian Straub, Steven Lovegrove, and Richard Newcombe. 2020. Deep local shapes: Learning local sdf priors for detailed 3d reconstruction. In *European Conference on Computer Vision*. Springer, 608–625.
- Eric R. Chan, Connor Z. Lin, Matthew A. Chan, Koki Nagano, Boxiao Pan, Shalini De Mello, Orazio Gallo, Leonidas Guibas, Jonathan Tremblay, Sameh Khamis, Tero Karras, and Gordon Wetzstein. 2022. Efficient Geometry-aware 3D Generative Adversarial Networks. In *CVPR*.
- Angel X Chang, Thomas Funkhouser, Leonidas Guibas, Pat Hanrahan, Qixing Huang, Zimo Li, Silvio Savarese, Manolis Savva, Shuran Song, Hao Su, et al. 2015. Shapenet: An information-rich 3d model repository. *arXiv preprint arXiv:1512.03012* (2015).
- Zhiqin Chen and Hao Zhang. 2019. Learning implicit fields for generative shape modeling. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 5939–5948.
- An-Chieh Cheng, Xueting Li, Sifei Liu, Min Sun, and Ming-Hsuan Yang. 2022. Autoregressive 3d shape generation via canonical mapping. *arXiv preprint arXiv:2204.01955* (2022).
- Julian Chibane, Thiemo Alldieck, and Gerard Pons-Moll. 2020. Implicit functions in feature space for 3d shape reconstruction and completion. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 6970–6981.
- Gene Chou, Yuval Bahat, and Felix Heide. 2022. DiffusionSDF: Conditional Generative Modeling of Signed Distance Functions. *arXiv preprint arXiv:2211.13757* (2022).
- Christopher Bongsoo Choy, Danfei Xu, JunYoung Gwak, Kevin Chen, and Silvio Savarese. 2016. 3D-R2N2: A Unified Approach for Single and Multi-view 3D Object Reconstruction. *European conference on computer vision* (2016), 628–644.
- Angela Dai, Christian Diller, and Matthias Nießner. 2020. Sg-nn: Sparse generative neural networks for self-supervised scene completion of rgb-d scans. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 849–858.
- Angela Dai, Charles Ruizhongtai Qi, and Matthias Nießner. 2017. Shape completion using 3d-encoder-predictor cnns and shape synthesis. In *Proceedings of the IEEE conference on computer vision and pattern recognition*. 5868–5877.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2018. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805* (2018).
- Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. 2021. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. *ICLR* (2021).
- Philipp Erler, Paul Guerrero, Stefan Ohrhallinger, Niloy J Mitra, and Michael Wimmer. 2020. Points2surf learning implicit surfaces from point clouds. In

- European Conference on Computer Vision. Springer, 108–124.
- Patrick Esser, Robin Rombach, and Bjorn Ommer. 2021. Taming transformers for high-resolution image synthesis. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 12873–12883.
- Kyle Genova, Forrester Cole, Avneesh Sud, Aaron Sarna, and Thomas Funkhouser. 2020. Local deep implicit functions for 3d shape. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 4857–4866.
- Rohit Girdhar, David F Fouhey, Mikel Rodriguez, and Abhinav Gupta. 2016. Learning a predictable and generative vector representation for objects. In *European Conference on Computer Vision*. Springer, 484–499.
- Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. 2014. Generative adversarial nets. *Advances in Neural Information Processing Systems* 27 (2014), 2672–2680.
- Meng-Hao Guo, Jun-Xiong Cai, Zheng-Ning Liu, Tai-Jiang Mu, Ralph R Martin, and Shi-Min Hu. 2021. Pct: Point cloud transformer. *Computational Visual Media* 7, 2 (2021), 187–199.
- Christian Häne, Shubham Tulsiani, and Jitendra Malik. 2017. Hierarchical surface prediction for 3d object reconstruction. In *2017 International Conference on 3D Vision (3DV)*. IEEE, 412–420.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. 2016. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*. 770–778.
- Jonathan Ho, Ajay Jain, and Pieter Abbeel. 2020. Denoising diffusion probabilistic models. *Advances in Neural Information Processing Systems* 33 (2020), 6840–6851.
- Ka-Hei Hui, Ruihui Li, Jingyu Hu, and Chi-Wing Fu. 2022. Neural wavelet-domain diffusion for 3d shape generation. In *SIGGRAPH Asia 2022 Conference Papers*. 1–9.
- Moritz Ibing, Isaak Lim, and Leif Kobbelt. 2021. 3d shape generation with grid-based implicit functions. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 13559–13568.
- Andrew Jaegle, Felix Gimeno, Andy Brock, Oriol Vinyals, Andrew Zisserman, and Joao Carreira. 2021. Perceiver: General perception with iterative attention. In *International conference on machine learning*. PMLR, 4651–4664.
- Chiyu Jiang, Avneesh Sud, Ameesh Makadia, Jingwei Huang, Matthias Nießner, Thomas Funkhouser, et al. 2020. Local implicit grid representations for 3d scenes. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 6001–6010.
- Tero Karras, Miika Aittala, Timo Aila, and Samuli Laine. 2022. Elucidating the Design Space of Diffusion-Based Generative Models. In *Proc. NeurIPS*.
- Diederik P. Kingma and Max Welling. 2014. Auto-Encoding Variational Bayes. In *International Conference on Learning Representations (ICLR)*, Yoshua Bengio and Yann LeCun (Eds.).
- Yann LeCun, Sumit Chopra, Raia Hadsell, M Ranzato, and F Huang. 2006. A tutorial on energy-based learning. *Predicting structured data* 1, 0 (2006).
- Tianyang Li, Xin Wen, Yu-Shen Liu, Hua Su, and Zhizhong Han. 2022. Learning deep implicit functions for 3D shapes with dynamic code clouds. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 12840–12850.
- William E Lorensen and Harvey E Cline. 1987. Marching cubes: A high resolution 3D surface construction algorithm. *ACM siggraph computer graphics* 21, 4 (1987), 163–169.
- Andreas Lugmayr, Martin Danelljan, Andrés Romero, Fisher Yu, Radu Timofte, and Luc Van Gool. 2022. RePaint: Inpainting using Denoising Diffusion Probabilistic Models. *ArXiv abs/2201.09865* (2022).
- Shitong Luo and Wei Hu. 2021. Diffusion probabilistic models for 3d point cloud generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2837–2845.
- Donald JR Meagher. 1980. Octree encoding: A new technique for the representation, manipulation and display of arbitrary 3-d objects by computer. Electrical and Systems Engineering Department Rensselaer Polytechnic ...
- Lars Mescheder, Michael Oechsle, Michael Niemeyer, Sebastian Nowozin, and Andreas Geiger. 2019. Occupancy networks: Learning 3d reconstruction in function space. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 4460–4470.
- Mateusz Michalkiewicz, Jhony K Pontes, Dominic Jack, Mahsa Baktashmotlagh, and Anders Eriksson. 2019. Deep level sets: Implicit surface representations for 3d shape inference. *arXiv preprint arXiv:1901.06802* (2019).
- Ben Mildenhall, Pratul P. Srinivasan, Matthew Tancik, Jonathan T. Barron, Ravi Ramamoorthi, and Ren Ng. 2020. NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis. In *ECCV*.
- Paritosh Mittal, Yen-Chi Cheng, Maneesh Singh, and Shubham Tulsiani. 2022. Autosdf: Shape priors for 3d completion, reconstruction and generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 306–315.
- Kaichun Mo, Paul Guerrero, Li Yi, Hao Su, Peter Wonka, Niloy Mitra, and Leonidas Guibas. 2019. StructureNet: Hierarchical Graph Networks for 3D Shape Generation. *ACM Transactions on Graphics (TOG), Siggraph Asia 2019* 38, 6 (2019), Article 242.
- Charlie Nash, Yaroslav Ganin, SM Ali Eslami, and Peter Battaglia. 2020. Polygen: An autoregressive generative model of 3d meshes. In *International conference on machine learning*. PMLR, 7220–7229.
- Jeong Joon Park, Peter Florence, Julian Straub, Richard Newcombe, and Steven Lovegrove. 2019. DeepSDF: Learning continuous signed distance functions for shape representation. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 165–174.
- Songyou Peng, Michael Niemeyer, Lars Mescheder, Marc Pollefeys, and Andreas Geiger. 2020. Convolutional occupancy networks. In *European Conference on Computer Vision*. Springer, 523–540.
- Ben Poole, Ajay Jain, Jonathan T Barron, and Ben Mildenhall. 2022. Dreamfusion: Text-to-3d using 2d diffusion. *arXiv preprint arXiv:2209.14988* (2022).
- Charles R Qi, Hao Su, Kaichun Mo, and Leonidas J Guibas. 2017a. Pointnet: Deep learning on point sets for 3d classification and segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*. 652–660.
- Charles Ruizhongtai Qi, Li Yi, Hao Su, and Leonidas J Guibas. 2017b. Pointnet++: Deep hierarchical feature learning on point sets in a metric space. *Advances in neural information processing systems* 30 (2017).
- Aditya Ramesh. 2022. Hierarchical Text-Conditional Image Generation with CLIP Latents.
- Danilo Rezende and Shakir Mohamed. 2015. Variational Inference with Normalizing Flows. In *International Conference on Machine Learning*. 1530–1538.
- Gernot Riegler, Ali Osman Ulusoy, Horst Bischof, and Andreas Geiger. 2017b. Octnetfusion: Learning depth fusion from data. In *2017 International Conference on 3D Vision (3DV)*. IEEE, 57–66.
- Gernot Riegler, Ali Osman Ulusoy, and Andreas Geiger. 2017a. Octnet: Learning deep 3d representations at high resolutions. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, Vol. 3.
- Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. 2022. High-resolution image synthesis with latent diffusion models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 10684–10695.
- Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily Denton, Seyed Kamyar Seyed Ghasemipour, Burcu Karagol Ayan, S Sara Mahdavi, Rapha Gontijo Lopes, et al. 2022. Photorealistic Text-to-Image Diffusion Models with Deep Language Understanding. *arXiv preprint arXiv:2205.11487* (2022).
- Mehdi SM Sajjadi, Olivier Bachem, Mario Lucic, Olivier Bousquet, and Sylvain Gelly. 2018. Assessing generative models via precision and recall. *Advances in neural information processing systems* 31 (2018).
- Mehdi SM Sajjadi, Henning Meyer, Etienne Pot, Urs Bergmann, Klaus Greff, Noha Radwan, Suhani Vora, Mario Lučić, Daniel Duckworth, Alexey Dosovitskiy, et al. 2022. Scene representation transformer: Geometry-free novel view synthesis through set-latent scene representations. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 6229–6238.
- J Ryan Shue, Eric Ryan Chan, Ryan Po, Zachary Ankner, Jiajun Wu, and Gordon Wetzstein. 2022. 3D Neural Field Generation using Triplane Diffusion. *arXiv preprint arXiv:2211.16677* (2022).
- Yongbin Sun, Yue Wang, Ziwei Liu, Joshua Siegel, and Sanjay Sarma. 2020. Pointgrow: Autoregressively learned point cloud generation with self-attention. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*. 61–70.

- Jiapeng Tang, Jiabao Lei, Dan Xu, Feiying Ma, Kui Jia, and Lei Zhang. 2021. Saccovnet: Sign-agnostic optimization of convolutional occupancy networks. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 6504–6513.
- Maxim Tatarchenko, Alexey Dosovitskiy, and Thomas Brox. 2017. Octree Generating Networks: Efficient Convolutional Architectures for High-resolution 3D Outputs. In *2017 IEEE International Conference on Computer Vision (ICCV)*. 2107–2115.
- Aaron Van Den Oord, Oriol Vinyals, et al. 2017. Neural discrete representation learning. *Advances in neural information processing systems* 30 (2017).
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. *Advances in neural information processing systems* 30 (2017).
- Peng-Shuai Wang, Yang Liu, Yu-Xiao Guo, Chun-Yu Sun, and Xin Tong. 2017. Ocnn: Octree-based convolutional neural networks for 3d shape analysis. *ACM Transactions on Graphics (TOG)* 36, 4 (2017), 72.
- Peng-Shuai Wang, Chun-Yu Sun, Yang Liu, and Xin Tong. 2018. Adaptive Ocnn: a patch-based deep representation of 3D shapes. In *SIGGRAPH Asia 2018 Technical Papers*. ACM, 217.
- Yue Wang, Yongbin Sun, Ziwei Liu, Sanjay E Sarma, Michael M Bronstein, and Justin M Solomon. 2019. Dynamic graph cnn for learning on point clouds. *Acm Transactions On Graphics (tog)* 38, 5 (2019), 1–12.
- Francis Williams, Zan Gojcic, Sameh Khamis, Denis Zorin, Joan Bruna, Sanja Fidler, and Or Litany. 2022. Neural fields as learnable kernels for 3d reconstruction. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 18500–18510.
- Jiajun Wu, Chengkai Zhang, Tianfan Xue, Bill Freeman, and Josh Tenenbaum. 2016. Learning a probabilistic latent space of object shapes via 3d generative-adversarial modeling. In *Advances in Neural Information Processing Systems*. 82–90.
- Zhirong Wu, Shuran Song, Aditya Khosla, Fisher Yu, Linguang Zhang, Xiaoou Tang, and Jianxiong Xiao. 2015. 3d shapenets: A deep representation for volumetric shapes. In *Proceedings of the IEEE conference on computer vision and pattern recognition*. 1912–1920.
- Jianwen Xie, Yang Lu, Song-Chun Zhu, and Yingnian Wu. 2016. A theory of generative convnet. In *International Conference on Machine Learning*. PMLR, 2635–2644.
- Jianwen Xie, Yifei Xu, Zilong Zheng, Song-Chun Zhu, and Ying Nian Wu. 2021. Generative pointnet: Deep energy-based learning on unordered point sets for 3d generation, reconstruction and classification. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 14976–14985.
- Jianwen Xie, Zilong Zheng, Ruiqi Gao, Wenguan Wang, Song-Chun Zhu, and Ying Nian Wu. 2020. Generative VoxelNet: learning energy-based models for 3D shape synthesis and analysis. *IEEE Transactions on Pattern Analysis and Machine Intelligence* (2020).
- Xingguang Yan, Liqiang Lin, Niloy J Mitra, Dani Lischinski, Daniel Cohen-Or, and Hui Huang. 2022. Shapeformer: Transformer-based shape completion via sparse representation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 6239–6249.
- Guandao Yang, Xun Huang, Zekun Hao, Ming-Yu Liu, Serge Belongie, and Bharath Hariharan. 2019. Pointflow: 3d point cloud generation with continuous normalizing flows. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 4541–4550.
- Xiaohui Zeng, Arash Vahdat, Francis Williams, Zan Gojcic, Or Litany, Sanja Fidler, and Karsten Kreis. 2022. LION: Latent Point Diffusion Models for 3D Shape Generation. *arXiv preprint arXiv:2210.06978* (2022).
- Biao Zhang, Matthias Nießner, and Peter Wonka. 2022. 3DILG: Irregular Latent Grids for 3D Generative Modeling. In *Advances in Neural Information Processing Systems*. <https://openreview.net/forum?id=RO0wSr3R7y->
- Hengshuang Zhao, Li Jiang, Jiaya Jia, Philip HS Torr, and Vladlen Koltun. 2021. Point transformer. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 16259–16268.
- Xin-Yang Zheng, Yang Liu, Peng-Shuai Wang, and Xin Tong. 2022. SDF-StyleGAN: Implicit SDF-Based StyleGAN for 3D Shape Generation. In *Comput. Graph. Forum (SGP)*.
- Linqi Zhou, Yilun Du, and Jiajun Wu. 2021. 3d shape generation and completion through point-voxel diffusion. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 5826–5835.