

LAGEM : 一种用于 3D 表示学习与扩散的 大几何模型

Biao Zhang, Peter Wonka

KAUST, Saudi Arabia

{biao.zhang, peter.wonka}@kaust.edu.sa

ABSTRACT

本文提出了一种新型分层自编码器，可将 3D 模型映射到高度压缩的潜在空间。该分层自编码器专门针对大规模数据集和基于扩散的生成式建模所面临的挑战而设计。与以往仅适用于规则图像或体素网格的方法不同，我们的分层自编码器在无序向量集上运行。编码器的每一层控制不同的几何细节层次。我们证明，该模型能够表示广泛的 3D 模型，同时忠实保留高分辨率几何细节。相较于基准模型，新架构的训练时间减少至 0.70 倍，内存使用降低至 0.58 倍。

我们还探讨了这种新表示在生成式建模中的应用。具体而言，我们提出一种级联扩散框架，其中每个阶段均依赖于前一阶段的条件。我们的设计将现有的用于图像和体素网格的级联结构扩展至向量集。

1 引言

扩散模型目前是图像、视频和 3D 物体生成性能最佳的模型。对于 3D 物体生成，研究主要分为两个方向。第一个方向由 Dreamfusion (Poole et al., 2022) 率先提出，旨在将 2D 扩散模型提升至 3D 模型生成。该方法的优势在于可以利用用于训练 2D 扩散模型的大规模 2D 数据集，并由此激发了大量后续工作 (Poole et al., 2022; Wang et al., 2023; Lin et al., 2023; Chen et al., 2023; Wang et al., 2024; Qian et al., 2023; Tang et al., 2023; Yi et al., 2023; Wang & Shi, 2023; Liu et al., 2024; Long et al., 2024; Zheng et al., 2024; Li et al., 2023; Ho et al., 2022; Xu et al., 2023)。第二个方向则直接在 3D 数据集上进行训练。该方法的优势在于更加直接，且推理速度更快 (Mittal et al., 2022; Yan et al., 2022; Zhang et al., 2022; Zeng et al., 2022; Zheng et al., 2023; Hui et al., 2022; Zhang et al., 2023; Siddiqui et al., 2024; Chen et al., 2024a;b)。我们的工作旨在为这一第二类方法做出贡献。

在这些 3D 原生生成方法中，3DShape2VecSet (Zhang et al., 2023)(or VecSet for short) 已被证明是一种有效编码 3D 几何形状的方法。该方法提出使用自编码器来寻找 3D 模型的高效表示，即一组向量。由于潜在空间具有较高的重构质量和紧凑性，该方法减轻了训练 3D 生成式模型的难度。其他一些工作 (Zhao et al., 2024; Cao et al., 2024; Dong et al., 2024; Petrov et al., 2024; Zhang et al., 2024b; Zhang & Wonka, 2024) 也采用了 VecSet 表示。

我们注意到，VecSet 的表达能力受限于潜在向量的数量。它在较小的数据集（如 ShapeNet）上出现过拟合现象，且无法扩展到更大的数据集。为了提升其表达能力，我们需要增加潜在向量的大小以及训练数据集的规模。直接的方法是使用数百个 GPU 进行训练，但这成本高昂 (Zhang et al., 2024b)。因此，我们的目标是在保持相似甚至更优的自动编码质量的同时，降低训练的时间和内存消耗成本。




图 1: **自编码器**。我们在此展示了不同的自编码器架构，包括 AE（自编码器）、U-Net、VAE (Kingma, 2013)、NVAE (Vahdat & Kautz, 2020)、VecSet (Zhang et al., 2023) 以及所提出的 LaGeM。VAE 和 NVAE 用于图像数据，而 VecSet 和 LaGeM 用于几何（距离函数）数据。在第一行中，VAE 和 VecSet 使用单一尺度的潜在表示来表示数据。NVAE 和 LaGeM 均使用多尺度潜在表示数据。此前的工作 VAE、NVAE 和 VecSet 均在瓶颈处应用 KL 散度以正则化潜在空间，而在本工作中，我们在瓶颈处应用标准化。

在图像领域，NVAE (Vahdat & Kautz, 2020) 将变分自编码器 (VAE) (Kingma, 2013) 的设计扩展为基于 U-Net 架构的分层 VAE。NVAE 的潜在空间是一个多尺度潜在网络，其图像重构质量相较于 VAE 显著提升。架构示意图见 Fig. 1。我们受到 NVAE 设计的启发，设计了一种多尺度潜在 VecSet 表示，称为 *LaGeM*。我们在大规模几何数据集 Objaverse (Deitke et al., 2023) 上训练该架构，相较于 VecSet，训练时间提升了 0.7 倍，内存消耗降低了 0.58 倍。

此外，我们还提出了一种用于分层潜在空间的级联生成模型。该模型从低分辨率层级逐步生成到最高分辨率层级的潜在向量集合。在每个阶段，我们使用先前生成的潜在变量作为条件信息。由此，可以控制生成几何细节的程度。

我们总结了我们的贡献如下：

- 我们提出一种分层自编码器架构，具有更快的训练速度和较低的内存消耗。潜在空间由多个层次组成。
- 该模型能够对大规模数据集（如 Objaverse）进行训练。
- 我们提出一种级联扩散模型，用于在分层潜在空间中生成三维几何形状。这使得能够控制生成模型的细节程度。

Latents	Controlling
Level 3	Main Structure
Level 2	Major Details
Level 1	Minor Details

2 相关作品

我们展示了 Table 1 中潜在 3D 生成式模型的概览，特别关注所使用的潜在空间类型。

2.1 学习方法

通常，需要一种学习方法将三维几何体转换为潜在空间。1) 一种方法是使用针对每个对象的最优化方法将三维几何体转换为潜在空间，例如 (Erkoç et al., 2023; Yariv et al., 2024)。

表 1: 几何潜在表示与生成。

Method	Learning Method	Latent Rep	Hierarchies
ShapeFormer (Yan et al., 2022)	AutoEncoder	Sparse Volume	Single
3DILG (Zhang et al., 2022)	AutoEncoder	Irregular Grid	Single
LION (Zeng et al., 2022)	AutoEncoder	Latent Points	Multi
TriplaneDiffusion (Shue et al., 2023)	AutoDeocder	Planes	Single
SDFusion (Cheng et al., 2023)	AutoEncoder	Volume	Single
3DShape2VecSet (Zhang et al., 2023)	AutoEncoder	VecSet	Single
HyperDiffusion (Erkoç et al., 2023)	Per-Object Optimization	Network Weight	Single
XCube (Ren et al., 2024)	AutoEncoder	Sparse Volume	Multi
Mosaic-SDF (Yariv et al., 2024)	Per-Object Optimization	Irregular Grid	Single
3DTopia-XL(Chen et al., 2024c)	Per-Object Optimization	Irregular Grid	Single
OctFusion (Xiong et al., 2024)	AutoEncoder	Sparse Volume	Multi
LaGeM  (Ours)	AutoEncoder	VecSet	Multi

对于较大的数据集，这种方法非常耗时。2) 另一种选择是自解码器，例如 DeepSDF (Park et al., 2019)，它联合优化数据集中所有对象的潜在空间。然而，由于没有编码器，新对象难以被映射到潜在空间。3) 因此，一种常用框架是自编码器。该方法的最优化效率高，因为它是对数据集中的所有对象同时进行的，且训练集之外的新对象可以利用编码器快速编码。因此，我们也基于这一方法进行构建。

2.2 潜在表示

早期的方法使用规则网格 (Yan et al., 2022; Cheng et al., 2023) 作为潜在表示，因为其结构简单。我们可以轻松地使用卷积层来处理体数据。为了表示高质量的几何细节，我们需要高分辨率的体数据。这使得训练更加困难，因为存在 $O(n^3)$ 复杂性。解决此问题的一种方法是引入稀疏性 (Ren et al., 2024) 到表示中，例如八叉树 (Xiong et al., 2024) 或稀疏不规则网格 (Zhang et al., 2022; Yariv et al., 2024)。这两种结构都有潜力表示高质量的三维模型，但扩散模型难以显式生成不规则结构。与上述方法不同，提出了一种 3DShape2VecSet (Zhang et al., 2023) 来在不使用任何稀疏结构的情况下解决重构问题。该表示易于使用。在本文中，我们研究如何改进 VecSet 表示。与 Zhang et al. (2023) 相比，我们的目标是通过引入潜在层级 (LoL) 获得更高质量的潜在空间。

2.3 级联生成

在图像生成领域，存在多种级联扩散模型，例如 (Ho et al., 2022; Saharia et al., 2022)。在 3D 领域，一些工作 (Zeng et al., 2022; Ren et al., 2024) 也利用分层潜在表示对几何结构进行建模，并提出了基于级联扩散模型的 3D 生成式模型。我们的工作将 3D 几何结构编码为分层 VecSets，因此在我们的潜在空间中考虑级联潜在扩散来训练生成式模型是直接可行的。




图 2: **流水线**. 我们提出了一种类似 U-Net 的 Transformer 用于自动编码。通过这种方式, 我们获得了一个分层的潜在空间, 其中包含多个层次的潜在表示。为了在潜在空间中训练生成式扩散模型, 我们提出了级联潜在扩散模型。

3 方法学

3.1 VECSET 表示的背景

VecSet (Zhang et al., 2023) 表示将稠密点云转换为潜在向量集 $\mathcal{Z} = \{\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_M\}$, 其中包含 $\mathbf{z} \in \mathbb{R}^D$, 使得可以从向量集中恢复占据/距离函数 $\mathcal{O}(\mathbf{p})$ 。简化后的网络如 Fig. 3 所示。

编码。 该过程首先通过最远点采样 (FPS) 对三维输入点云 $\mathcal{P}^{\text{Input}} = \{\mathbf{p}_i\}_{i=1, \dots, N}$ 进行下采样, $\mathcal{P} = \text{FPS}(\mathcal{P}^{\text{Input}}, r)$, 其中 r 为下采样比率, $\mathcal{P}$ 为 $\mathcal{P}^{\text{Input}}$ 的低分辨率版本。然后将 $\mathcal{P}^{\text{Input}}$ 转换为无序集合, 采用交叉注意力

$$\text{CA}(Q = \text{PE}(\mathcal{P}), K = \text{PE}(\mathcal{P}^{\text{Input}}), V = \text{PE}(\mathcal{P}^{\text{Input}})) = \mathcal{X} = \{\mathbf{x} \in \mathbb{R}^C\}_{i=1, 2, \dots, M}, \quad (1)$$

其中, PE 是位置嵌入函数 (Zhang et al., 2023), $\text{CA}(\cdot, \cdot, \cdot)$ 为交叉注意力模块。我们简写 $\text{CA}(\mathcal{P}, \mathcal{P}^{\text{Input}})$ 。此处为了简化, 省略了将三维坐标 $\mathbf{p} \in \mathbb{R}^3$ 映射到高维空间 $\mathbb{R}^C$ 的位置嵌入。为了获得高度压缩的潜在空间, $\mathcal{X}$ 中的向量进一步被压缩至低维空间 $\mathbb{R}^D$, 其中 $D \leq C$ (特征到潜在, 或简称 FtoL),

$$\text{FtoL}(\mathcal{X}) = \mathcal{Z} = \{\mathbf{z} \in \mathbb{R}^D\}_{i=1, 2, \dots, M}. \quad (2)$$

此压缩步骤也通过 KL 散度进行正则化。

解码 $\mathcal{Z}$ 中的每个潜在向量首先被转换回特征空间 $\mathbb{R}^C$ (潜在到特征, 简称 LtoF),

$$\text{LtoF}(\mathcal{Z}) = \mathcal{X}' = \{\mathbf{x}' \in \mathbb{R}^C\}_{i=1, 2, \dots, M}. \quad (3)$$

特征 $\mathcal{X}'$ 被输入到一系列自注意力层中, 以获得最终的占用/距离函数表示 $\mathcal{F}$,

$$\text{SAs}(\mathcal{X}') = \mathcal{F} = \{\mathbf{f} \in \mathbb{R}^C\}_{i=1, 2, \dots, M}, \quad (4)$$

其中 $\text{SAs}(\cdot)$ 通过多个自注意力层实现。现在我们可以解码一个连续函数。对于空间中的连续坐标 $\mathbb{R}^3$, 我们有

$$\mathcal{O}(\mathbf{p}) = \text{FC}(\text{CA}(\mathbf{p}, \mathcal{F})) \in \mathbb{R}. \quad (5)$$

有关 FtoL($\cdot$) 和 LtoF($\cdot$) 的更多详细信息, 请参见 Table 2。

3.2 分层向量设置

Eq. (4) 中自注意力层的复杂度为 $O(M^2)$, 即与输入向量数量的平方成正比。当 M 较大时, 这会严重影响训练时间。然而, 为了表示高质量的几何细节, 我们通常需要较大的 M 。这使得训练大型 VecSet 网络更具挑战性 (例如 CLAY (Zhang et al., 2024a) 中的 $M = 2048$)。




图 3: 几何自编码器。VecSet (Zhang et al., 2023) 的设计可以看作是所提出的 LaGeM 网络在仅有一个层级时的特殊情况。




图 4: LaGeM 架构。我们展示了一个包含 3 层潜在变量的示意图。

受 U-Net 和 NVAE (Vahdat & Kautz, 2020) 设计的启发，我们提出了一种新网络。具体而言，在 U-Net 的设计中（见 Fig. 1 的示意图），图像特征网格被下采样至较低分辨率，并在该分辨率上应用部分卷积块，然后上采样回原始分辨率。通过这种方式，我们可以避免在高分辨率图像上执行卷积层（这可能耗时较长）。我们将这一思想迁移到 VecSet 表示中。两个必要的构建模块是用于对 VecSet 进行下采样和上采样的操作。受 3DShape2VecSet (Zhang et al., 2023) (an illustration can be found in Fig. 3) 设计的启发，我们将编码器部分中的交叉注意力解释为一个下采样算子。类似地，我们也可以将其用于上采样。最终得到的网络如 Fig. 4 所示。

我们在 U-Net 风格的 Transformer 中设有 L 个层级，从 1（最高分辨率）到 L （最低分辨率）进行编号。为方便记号，我们将输入点云记为第 0 层。在第 i 层，我们首先获得第 $(i-1)$ 层点云的低分辨率表示， $\text{FPS}(\mathcal{P}_{i-1}, r_{i-1}) = \mathcal{P}_i$ 其中 $\mathcal{P}_0$ 为输入点云。我们使用交叉注意力来压缩特征集 $\text{CA}(\mathcal{P}_i, \mathcal{P}_{i-1}) = \mathcal{X}_i$ 。与以往方法不同，我们提出一种新的方式来正则化潜在空间，

$$\text{FtoL}(\mathcal{X}_i) = \text{ZeroMeanAndUnitVariance}(\text{FC}_{\text{down}}(\mathcal{X}_i)) = \mathcal{Z}_i, \quad (6)$$

其中，我们将集合中的每个向量归一化为零均值和单位方差 $(\mathbf{z} - \mathbb{E}[\mathbf{z}]) / \sqrt{\text{Var}[\mathbf{z}]}$ （在机器学习中通常称为 标准化，用于将数据中的特征标准化到固定值域）。这种设计的动机在于，扩散过程从具有零均值和单位方差的高斯噪声开始。通过这种方式，我们强制潜在空间和初始高斯噪声具有相似的特性。为了将潜在变量映射回特征，我们首先对潜在变量进行缩放和偏移 $\mathbf{z} \odot \gamma + \beta$ （其中 γ 和 β 是可学习参数，类似于层规范化 (Lei Ba et al., 2016) 中的做法）。

$$\text{LtoF}(\mathcal{Z}_i) = \text{FC}_{\text{up}}(\text{ScaleAndShift}(\mathcal{Z}_i)) = \mathcal{X}'_i. \quad (7)$$

表 2: 瓶颈处的正则化。我们比较了所提出的正则化方法与 VAE。我们无需显式损失来正则化潜在空间。

	Features to Latents (FtoL)	Latent Loss	Latents to Features (LtoF)
VAE	$\mu = \text{FC}_{\mu}(\mathbf{x})$ $\sigma = \text{FC}_{\sigma}(\mathbf{x})$ $\mathbf{z} = \mu + \sigma \odot \epsilon$	KL Divergence	$\mathbf{x}' = \text{FC}_{\text{up}}(\mathbf{z})$
Ours	$\bar{\mathbf{z}} = \text{FC}_{\text{down}}(\mathbf{x})$ $\mathbf{z} = \frac{\bar{\mathbf{z}} - \mathbb{E}[\bar{\mathbf{z}}]}{\sqrt{\text{Var}[\bar{\mathbf{z}}]}}$	-	$\mathbf{x}' = \text{FC}_{\text{up}}(\mathbf{z} \odot \gamma + \beta)$

与变分自编码器中的 KL 散度不同，我们不需要潜在空间的显式损失项。参见 Table 2，比较所提出的正则化方法与变分自编码器中常用的 KL 散度。

受 Zhang et al. (2023) 中交叉注意力的下采样用法启发，我们将之推广至重采样。此处我们将其用于无序集合的上采样 $\mathcal{F}_i$ 。在将特征输入自注意力层之前，我们首先从低分辨率层级上采样特征 $\mathcal{F}_{i+1}$ ，并应用自注意力机制，

$$\text{SAs}(\text{CA}(\mathcal{X}'_i, \mathcal{F}_{i+1})) = \mathcal{F}_i. \quad (8)$$

命令 Eq. (5) 中的查询函数已更改为

$$\mathcal{O}(\mathbf{p}) = \text{FC}([\text{CA}(\mathbf{p}, \mathcal{F}_1) | \cdots | \text{CA}(\mathbf{p}, \mathcal{F}_L)]) \in \mathbb{R}, \quad (9)$$

其中 $[\cdot | \cdots | \cdot]$ 是连接的符号。这意味着我们使用所有层次的特征来构建最终（占据）函数表示 (Fig. 5)。




图 5: 多分辨率特征

3.3 扩散

级联扩散 (Ho et al., 2022) 提出了一种生成高分辨率图像的方法。该方法由多个阶段组成，每个阶段均为一个条件扩散模型。受此启发，我们提出了一个级联潜在扩散模型。在级联扩散中，前一阶段生成的图像被用作下一阶段的条件。我们基于级联扩散构建了一个级联潜在扩散模型。形式上，最优化目标（针对我们的三级实现）如下，

$$\begin{aligned} \min_{D_3} & \left\| D_3(\tilde{\mathcal{Z}}_3(t), t, \mathcal{C}) - \mathcal{Z}_3 \right\|, \\ \min_{D_2} & \left\| D_2(\tilde{\mathcal{Z}}_2(t), t, \mathcal{C}, \mathcal{Z}_3) - \mathcal{Z}_2 \right\|, \\ \min_{D_1} & \left\| D_1(\tilde{\mathcal{Z}}_1(t), t, \mathcal{C}, \mathcal{Z}_3, \mathcal{Z}_2) - \mathcal{Z}_1 \right\|, \end{aligned} \quad (10)$$

其中 D_i 为降噪网络， t 表示时间步或噪声等级， $\tilde{\mathcal{Z}}_i(t)$ 为在时间步 t 时的潜在变量的加噪版本， $\mathcal{C}$ 为可选的条件信息（例如，文本、图像或类别）。该网络设计基于 DiT (Peebles & Xie, 2022)。为了生成潜在变量 $\mathcal{Z}_i$ ，我们需要前一阶段的潜在变量 $\mathcal{Z}_{>i}$ 。对于基于扩散模型的图像超分辨率方法，通常通过双线性插值小图像并将它们与降噪网络的输入拼接来实现。如前一节所示，我们使用交叉注意力进行重采样（包括下采样和上采样）。在此，我们也利用交叉注意力对潜在变量集进行上采样。具体而言，假设我们正在训练一个用于 $\mathcal{Z}_2$ 的降噪网络，网络的输入为 $\tilde{\mathcal{Z}}_2(t)$ ，

$$\text{CA}(\tilde{\mathcal{Z}}_2(t), \mathcal{Z}_3). \quad (11)$$

同样地，对于 $\mathcal{Z}_1$ ，

$$\text{CA}(\text{CA}(\tilde{\mathcal{Z}}_1(t), \mathcal{Z}_3), \mathcal{Z}_2). \quad (12)$$

这样，我们正在收集先前阶段的信息。参见 Fig. 6 了解流水线的示意图。

4 实验

4.1 自编码模型

主要的自编码实验在 Objaverse (Deitke et al., 2023) 上进行训练。模型经过零中心化并规范化至单位球面。由于该数据集中大多数 3D 模型并非封闭，我们使用 ManifoldPlus (Huang et al., 2020) 使所有网格封闭。由于建模加载和转换失败，我们共获得约 60 万张封闭模型用于训练。三个层级的潜在表示分别为 128×64 、 512×32 和 2048×16 （其中 64、32 和




图 6: 级联潜在扩散

表 3: **LaGeM 的运行统计**。在使用较少的潜在向量（512 个）时，我们的模型在训练过程中仅需 0.87 倍的时间和 0.66 倍的内存。对于更大的模型（2048 个潜在向量），优势更加显著（时间减少至 0.7 倍，内存减少至 0.58 倍）。

	VecSet		LaGeM		VecSet		LaGeM		VecSet		LaGeM	
Batch Size	64		8		8		4		4		4	
Self Attn Layers	24	8/8/8	24	8/8/8	24	8/8/8	24	8/8/8	24	8/8/8	24	8/8/8
Attn Channels	512	512/512/512	1k	1k/1k/1k	1k	1k/1k/1k	1k	1k/1k/1k	1k	1k/1k/1k	1k	1k/1k/1k
# Parameters (M)	106.13	125.15	424.24	499.85	424.24	499.85	424.24	499.85	424.24	499.85	424.24	499.85
# Latent Vectors	512	32/128/512	2k	128/512/2k	2k	128/512/2k	2k	128/512/2k	2k	128/512/2k	2k	128/512/2k
# Latent Channels	8	32/16/8	64	64/32/16	64	64/32/16	64	64/32/16	64	64/32/16	64	64/32/16
Training Memory (M)	56,125	37,055 (0.66×)	OOM	53,791 (-)	54,543	31,662 (0.58×)	54,543	31,662 (0.58×)	54,543	31,662 (0.58×)	54,543	31,662 (0.58×)
Training Iteration (sec)	0.6481	0.5658 (0.87×)	-	0.7714 (-)	0.6902	0.4853 (0.70×)	0.6902	0.4853 (0.70×)	0.6902	0.4853 (0.70×)	0.6902	0.4853 (0.70×)

表 4: 在 ShapeNet 上的评估。我们将结果与在 ShapeNet 上训练的 VecSet (Zhang et al., 2023) 进行比较。如果我们使用 ShapeNet 训练我们的模型并在 ShapeNet 上进行评估, 我们的模型略优于 VecSet。当我们的模型在 Objaverse 上训练并在 ShapeNet 上进行评估时, 可以观察到显著的提升。需要注意的是, 将 VecSet 扩展到在 Objaverse 上训练非常困难。

	Chamfer $\downarrow$ ($\times 100$)					F-Score $\uparrow$ ($\times 100$)				
	VS	LaGeM(Δ)				VS	LaGeM(Δ)			
		ShapeNet	Objaverse				ShapeNet	Objaverse		
table	2.46	2.48	0.02	2.09	-0.37	99.94	99.97	0.02	99.96	0.02
car	5.99	5.89	-0.10	4.36	-1.63	89.85	90.31	0.46	92.15	2.30
chair	2.92	2.89	-0.03	2.01	-0.91	96.40	96.49	0.09	99.91	3.51
airplane	1.78	1.81	0.03	1.58	-0.21	99.50	99.48	-0.02	99.78	0.29
sofa	2.64	2.63	-0.01	2.25	-0.39	98.92	99.04	0.11	99.60	0.67
rifle	1.78	1.77	-0.01	1.44	-0.34	99.88	99.88	-0.01	99.94	0.06
lamp	4.36	4.44	0.08	2.37	-2.00	96.78	97.18	0.39	99.43	2.64
mean (selected)	3.13	3.13	0.00	2.30	-0.83	97.33	97.48	0.15	98.68	1.36
mean (all)	4.68	4.63	-0.04	2.42	-2.26	93.25	93.47	0.23	98.93	5.68




图 7: ShapeNet 上的泛化性能。我们的结果在所有类别上均优于 VecSet。在小类别上, 由于训练样本有限, VecSet 的结果不够稳定。相比之下, 我们的训练模型在这些类别上也表现良好。

16 为潜在表示的通道数)。网络的其他超参数也可在 Table 3 中找到。我们将该模型命名为 LaGeM-Objaverse。我们还将该方法应用于 ShapeNet, 其训练集来自 (Zhang et al., 2022)。由于 ShapeNet 相较于 Objaverse 是一个相对较小且简单的数据集, 我们选择更小的潜在表示, 分别为 32×32 、 128×16 和 512×8 。该模型命名为 LaGeM-ShapeNet。两个模型均与 VecSet (Zhang et al., 2023) 进行对比。我们采用 Chamfer 距离和 F 分数作为评估指标。结果如 Table 4 所示。如 (Zhang et al., 2023) 所示, 我们首先比较 ShapeNet 中最大类别 (具有数千个训练样本) 的结果, 然后是所有类别。可以看出, LaGeM-ShapeNet 的参数数量几乎与 VecSet 相当, 但训练时间显著缩短, 训练内存消耗也更低。定量结果 (对 ShapeNet 所有类别的平均值) 也优于 VecSet。而对于 LaGeM-Objaverse, 训练成本和定量结果均有大幅提升。定量结果显示, 在完整数据集上, 以 Chamfer 距离为度量标准, 平均提升接近 50%。这表明 LaGeM-Objaverse 具有良好的泛化能力。这一点在 Fig. 7 中也可观察到。LaGeM-Objaverse 在 ShapeNet 的小类别上表现良好。在以往的工作中 (Zhang et al., 2023), 由于训练样本有限, 这种情况几乎是不可能实现的。

表 5: 在多种数据集上的泛化能力。我们训练的模型能够在多个现有数据集上进行推理。即使模型是在封闭数据集上训练的, 也能应用于非封闭数据集, 如 ABO 和 pix3d。需要注意的是, ShapeNet 中的模型原本并非封闭的。我们使用了由 (Zhang et al., 2022) 处理后的封闭版本。ShapeNet-test 的评估指标与 Table 4 不同, 这是因为此处展示的是所有物体上的平均指标, 而非按类别计算。

Dataset	# Meshes	Manifold	Chamfer $\downarrow$ ($\times 100$)			F-Score $\uparrow$ ($\times 100$)		
			VS	LaGeM(Δ)		VS	LaGeM(Δ)	
Thingi10k (Zhou & Jacobson, 2016)	10k	Yes	4.52	2.99	-1.53	92.75	97.19	4.44
ABO (Collins et al., 2022)	8k	No	4.91	3.66	-1.26	92.52	94.91	2.39
ShapeNet (Chang et al., 2015)-test	2k	Yes	3.25	2.33	-0.92	97.41	99.49	2.08
EGAD (Morrison et al., 2020)	2k	Yes	3.27	2.82	-0.45	99.02	99.76	0.74
GSO (Downs et al., 2022)	1k	Yes	3.78	2.35	-1.43	94.70	99.54	4.84
pix3d (Sun et al., 2018)	700	No	6.53	6.02	-0.50	87.25	87.96	0.71
FAUST (Bogo et al., 2014)	100	Yes	2.10	1.31	-0.79	99.58	99.90	0.32



图 8: ShapeNet 上的定性结果。我们展示了 ShapeNet 上的自编码结果。我们使用 VecSet 作为基准。我们的模型能够重建出详细的几何结构, 尤其是细长结构。




图 9: Thingi10k 上的定性结果。我们的模型甚至可以保留 CAD 模型中的高度详细几何结构。




图 10: FAUST 和 GSO 上的定性结果。VecSet 的结果过于平滑，而我们的方法能够保持锐利的细节。




图 11: 基于类别的 ShapeNet 生成结果。



图 12: Objaverse-10k 上的无条件生成结果。

为了进一步证明 LaGeM-Objaverse 的泛化能力，我们还在多种数据集上测试了自编码性能，包括 Thingi10k (Zhou & Jacobson, 2016)、ABO (Collins et al., 2022)、EGAD (Morrison et al., 2020)、GSO (Downs et al., 2022)、pix3d (Sun et al., 2018) 以及 FAUST (Bogo et al., 2014)。这些数据集中的物体涵盖了日常物品、CAD 模型、人体模型和合成物体。定量结果见 Table 5。我们再次使用 VecSet 的模型作为基准。从指标来看，LaGeM-Objaverse 能够以高度详细的几何结构和锐利的特征表示各类物体。值得注意的是，即使对于非封闭网格，该模型仍能完成重构。该方法的可视化结果见 Fig. 8、Fig. 9、Fig. 10。

4.2 生成式模型

我们进行了两次生成实验，一次是在 ShapeNet 上以类别作为条件的生成，另一次是在 Objaverse-10k 上的无条件生成。对于 ShapeNet，三级的降噪网络均包含 12 个自注意力块，通道数为 768。我们使用 4 块 A100 GPU 训练模型约 200 小时。结果如 Fig. 11 所示。对于 Objaverse-10k，由于训练 GPU 资源有限，我们从 Objaverse 中选取了 10,000 个模型的子集，并训练无条件生成模型。潜在变量在所有阶段均包含 24 个自注意力块，通道数为 768。模型在 16 块 A100 GPU 上训练了约 100 小时。详见 Fig. 12 中的部分无条件生成结果。

潜在变量的可控性。 我们验证了不同层次的潜在变量控制生成样本的不同细节层级。在生成过程中，我们首先生成高层潜在变量 $\mathcal{Z}_3$ ，它决定了三维模型的主要结构。然后，我们以 $\mathcal{Z}_3$ 作为条件生成 $\mathcal{Z}_2$ ，为模型添加主要细节。最后，我们在同时依赖 $\mathcal{Z}_3$ 和 $\mathcal{Z}_2$ 的条件下生成 $\mathcal{Z}_1$ 。这一步骤为样本添加了一些细微的细节。可视化示例见 Fig. 13。




图 13: **潜在层级**。每个小型 4×4 块共享相同的第 3 层潜在变量 Z_3 。同一块中的 3D 模型具有相似的结构。在每个块中，每一行 1×4 共享相同的第 2 层潜在变量 Z_2 。在块的每一行中，3D 模型几乎相同，仅在一些细微细节上有所不同。因此，我们认为 Z_3 控制结构， Z_2 影响主要细节，而 Z_1 负责细微细节。

5 结论

我们提出了 LaGeM（大型几何模型），这是一种用于编码三维几何形状的架构。与以往方法不同，我们的潜在空间被建模为分层的潜在 VecSets。为了实现这一目标，我们的模型采用类 U-Net 的设计，并引入了一种新的瓶颈正则化技术。我们证明了该模型在训练速度上显著提升，且所需的 GPU 内存大幅降低，尤其适用于更大规模的网络和数据集。这使得网络能够扩展至大规模数据集。我们发布了基于 60 万几何数据集训练的模型。此外，我们提出了一种级联扩散模型，展示了利用分层潜在空间生成结果的初步效果。

限制 由于潜在空间被划分为多个层次，对所有层次训练扩散模型仍然需要大量时间。我们的方法并未解决扩散模型本身带来的高训练成本问题。

参考文献

- Federica Bogo, Javier Romero, Matthew Loper, and Michael J Black. Faust: Dataset and evaluation for 3d mesh registration. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 3794–3801, 2014.
- Wei Cao, Chang Luo, Biao Zhang, Matthias Nießner, and Jiapeng Tang. Motion2vecsets: 4d latent vector set diffusion for non-rigid shape reconstruction and tracking. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 20496–20506, 2024.
- Angel X Chang, Thomas Funkhouser, Leonidas Guibas, Pat Hanrahan, Qixing Huang, Zimo Li, Silvio Savarese, Manolis Savva, Shuran Song, Hao Su, et al. Shapenet: An information-rich 3d model repository. *arXiv preprint arXiv:1512.03012*, 2015.
- Rui Chen, Yongwei Chen, Ningxin Jiao, and Kui Jia. Fantasia3d: Disentangling geometry and appearance for high-quality text-to-3d content creation. In *Proceedings of the IEEE/CVF international conference on computer vision*, pp. 22246–22256, 2023.
- Sijin Chen, Xin Chen, Anqi Pang, Xianfang Zeng, Wei Cheng, Yijun Fu, Fukun Yin, Yanru Wang, Zhibin Wang, Chi Zhang, et al. Meshxl: Neural coordinate field for generative 3d foundation models. *arXiv preprint arXiv:2405.20853*, 2024a.
- Yiwen Chen, Tong He, Di Huang, Weicai Ye, Sijin Chen, Jiaxiang Tang, Xin Chen, Zhongang Cai, Lei Yang, Gang Yu, et al. Meshanything: Artist-created mesh generation with autoregressive transformers. *arXiv preprint arXiv:2406.10163*, 2024b.
- Zhaoxi Chen, Jiaxiang Tang, Yuhao Dong, Ziang Cao, Fangzhou Hong, Yushi Lan, Tengfei Wang, Haozhe Xie, Tong Wu, Shunsuke Saito, et al. 3dtopia-xl: Scaling high-quality 3d asset generation via primitive diffusion. *arXiv preprint arXiv:2409.12957*, 2024c.
- Yen-Chi Cheng, Hsin-Ying Lee, Sergey Tulyakov, Alexander G Schwing, and Liang-Yan Gui. Sdfusion: Multimodal 3d shape completion, reconstruction, and generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 4456–4465, 2023.
- Jasmine Collins, Shubham Goel, Kenan Deng, Achleshwar Luthra, Leon Xu, Erhan Gundogdu, Xi Zhang, Tomas F Yago Vicente, Thomas Dideriksen, Himanshu Arora, et al. Abo: Dataset and benchmarks for real-world 3d object understanding. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 21126–21136, 2022.
- Matt Deitke, Dustin Schwenk, Jordi Salvador, Luca Weihs, Oscar Michel, Eli VanderBilt, Ludwig Schmidt, Kiana Ehsani, Aniruddha Kembhavi, and Ali Farhadi. Objaverse: A universe of annotated 3d objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 13142–13153, 2023.
- Yuan Dong, Qi Zuo, Xiaodong Gu, Weihao Yuan, Zhengyi Zhao, Zilong Dong, Liefeng Bo, and Qixing Huang. Gpld3d: Latent diffusion of 3d shape generative models by enforcing geometric and physical priors. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 56–66, 2024.

-
- Laura Downs, Anthony Francis, Nate Koenig, Brandon Kinman, Ryan Hickman, Krista Reymann, Thomas B McHugh, and Vincent Vanhoucke. Google scanned objects: A high-quality dataset of 3d scanned household items. In *2022 International Conference on Robotics and Automation (ICRA)*, pp. 2553–2560. IEEE, 2022.
- Ziya Erkoç, Fangchang Ma, Qi Shan, Matthias Nießner, and Angela Dai. Hyperdiffusion: Generating implicit neural fields with weight-space diffusion. In *Proceedings of the IEEE/CVF international conference on computer vision*, pp. 14300–14310, 2023.
- Jonathan Ho, Chitwan Saharia, William Chan, David J Fleet, Mohammad Norouzi, and Tim Salimans. Cascaded diffusion models for high fidelity image generation. *Journal of Machine Learning Research*, 23(47):1–33, 2022.
- Jingwei Huang, Yichao Zhou, and Leonidas Guibas. Manifoldplus: A robust and scalable watertight manifold surface generation method for triangle soups. *arXiv preprint arXiv:2005.11621*, 2020.
- Ka-Hei Hui, Ruihui Li, Jingyu Hu, and Chi-Wing Fu. Neural wavelet-domain diffusion for 3d shape generation. In *SIGGRAPH Asia 2022 Conference Papers*, pp. 1–9, 2022.
- Tero Karras, Miika Aittala, Timo Aila, and Samuli Laine. Elucidating the design space of diffusion-based generative models. *Advances in neural information processing systems*, 35:26565–26577, 2022.
- Diederik P Kingma. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*, 2013.
- Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E Hinton. Layer normalization. *ArXiv e-prints*, pp. arXiv–1607, 2016.
- Jiahao Li, Hao Tan, Kai Zhang, Zexiang Xu, Fujun Luan, Yinghao Xu, Yicong Hong, Kalyan Sunkavalli, Greg Shakhnarovich, and Sai Bi. Instant3d: Fast text-to-3d with sparse-view generation and large reconstruction model. *arXiv preprint arXiv:2311.06214*, 2023.
- Chen-Hsuan Lin, Jun Gao, Luming Tang, Towaki Takikawa, Xiaohui Zeng, Xun Huang, Karsten Kreis, Sanja Fidler, Ming-Yu Liu, and Tsung-Yi Lin. Magic3d: High-resolution text-to-3d content creation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 300–309, 2023.
- Minghua Liu, Chao Xu, Haian Jin, Linghao Chen, Mukund Varma T, Zexiang Xu, and Hao Su. One-2-3-45: Any single image to 3d mesh in 45 seconds without per-shape optimization. *Advances in Neural Information Processing Systems*, 36, 2024.
- Xiaoxiao Long, Yuan-Chen Guo, Cheng Lin, Yuan Liu, Zhiyang Dou, Lingjie Liu, Yuexin Ma, Song-Hai Zhang, Marc Habermann, Christian Theobalt, et al. Wonder3d: Single image to 3d using cross-domain diffusion. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 9970–9980, 2024.
- Paritosh Mittal, Yen-Chi Cheng, Maneesh Singh, and Shubham Tulsiani. Autosdf: Shape priors for 3d completion, reconstruction and generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 306–315, 2022.

-
- Douglas Morrison, Peter Corke, and Jürgen Leitner. Egad! an evolved grasping analysis dataset for diversity and reproducibility in robotic manipulation. *IEEE Robotics and Automation Letters*, 5(3):4368–4375, 2020.
- Jeong Joon Park, Peter Florence, Julian Straub, Richard Newcombe, and Steven Lovegrove. DeepSDF: Learning continuous signed distance functions for shape representation. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 165–174, 2019.
- William Peebles and Saining Xie. Scalable diffusion models with transformers. *arXiv preprint arXiv:2212.09748*, 2022.
- Dmitry Petrov, Pradyumn Goyal, Vikas Thamizharasan, Vladimir Kim, Matheus Gadelha, Melinos Averkiou, Siddhartha Chaudhuri, and Evangelos Kalogerakis. Gem3d: Generative medial abstractions for 3d shape synthesis. In *ACM SIGGRAPH 2024 Conference Papers*, pp. 1–11, 2024.
- Ben Poole, Ajay Jain, Jonathan T Barron, and Ben Mildenhall. Dreamfusion: Text-to-3d using 2d diffusion. *arXiv preprint arXiv:2209.14988*, 2022.
- Guocheng Qian, Jinjie Mai, Abdullah Hamdi, Jian Ren, Aliaksandr Siarohin, Bing Li, Hsin-Ying Lee, Ivan Skorokhodov, Peter Wonka, Sergey Tulyakov, et al. Magic123: One image to high-quality 3d object generation using both 2d and 3d diffusion priors. *arXiv preprint arXiv:2306.17843*, 2023.
- Xuanchi Ren, Jiahui Huang, Xiaohui Zeng, Ken Museth, Sanja Fidler, and Francis Williams. Xcube: Large-scale 3d generative modeling using sparse voxel hierarchies. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 4209–4219, 2024.
- Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily L Denton, Kamyar Ghasemipour, Raphael Gontijo Lopes, Burcu Karagol Ayan, Tim Salimans, et al. Photorealistic text-to-image diffusion models with deep language understanding. *Advances in neural information processing systems*, 35:36479–36494, 2022.
- J Ryan Shue, Eric Ryan Chan, Ryan Po, Zachary Ankner, Jiajun Wu, and Gordon Wetzstein. 3d neural field generation using triplane diffusion. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 20875–20886, 2023.
- Yawar Siddiqui, Antonio Alliegro, Alexey Artemov, Tatiana Tommasi, Daniele Sirigatti, Vladislav Rosov, Angela Dai, and Matthias Nießner. Meshgpt: Generating triangle meshes with decoder-only transformers. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 19615–19625, 2024.
- Xingyuan Sun, Jiajun Wu, Xiuming Zhang, Zhoutong Zhang, Chengkai Zhang, Tianfan Xue, Joshua B Tenenbaum, and William T Freeman. Pix3d: Dataset and methods for single-image 3d shape modeling. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 2974–2983, 2018.

-
- Jiaxiang Tang, Jiawei Ren, Hang Zhou, Ziwei Liu, and Gang Zeng. Dreamgaussian: Generative gaussian splatting for efficient 3d content creation. *arXiv preprint arXiv:2309.16653*, 2023.
- Arash Vahdat and Jan Kautz. Nvae: A deep hierarchical variational autoencoder. *Advances in neural information processing systems*, 33:19667–19679, 2020.
- Haochen Wang, Xiaodan Du, Jiahao Li, Raymond A Yeh, and Greg Shakhnarovich. Score jacobian chaining: Lifting pretrained 2d diffusion models for 3d generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 12619–12629, 2023.
- Peng Wang and Yichun Shi. Imagedream: Image-prompt multi-view diffusion for 3d generation. *arXiv preprint arXiv:2312.02201*, 2023.
- Zhengyi Wang, Cheng Lu, Yikai Wang, Fan Bao, Chongxuan Li, Hang Su, and Jun Zhu. Prolificdreamer: High-fidelity and diverse text-to-3d generation with variational score distillation. *Advances in Neural Information Processing Systems*, 36, 2024.
- Bojun Xiong, Si-Tong Wei, Xin-Yang Zheng, Yan-Pei Cao, Zhouhui Lian, and Peng-Shuai Wang. Octfusion: Octree-based diffusion models for 3d shape generation. *arXiv preprint arXiv:2408.14732*, 2024.
- Yinghao Xu, Hao Tan, Fujun Luan, Sai Bi, Peng Wang, Jiahao Li, Zifan Shi, Kalyan Sunkavalli, Gordon Wetzstein, Zexiang Xu, et al. Dmv3d: Denoising multi-view diffusion using 3d large reconstruction model. *arXiv preprint arXiv:2311.09217*, 2023.
- Xingguang Yan, Liqiang Lin, Niloy J Mitra, Dani Lischinski, Daniel Cohen-Or, and Hui Huang. Shapeformer: Transformer-based shape completion via sparse representation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 6239–6249, 2022.
- Lior Yariv, Omri Puny, Oran Gafni, and Yaron Lipman. Mosaic-sdf for 3d generative models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 4630–4639, 2024.
- Taoran Yi, Jiemin Fang, Guanjun Wu, Lingxi Xie, Xiaopeng Zhang, Wenyu Liu, Qi Tian, and Xingang Wang. Gaussiandreamer: Fast generation from text to 3d gaussian splatting with point cloud priors. *arXiv preprint arXiv:2310.08529*, 2023.
- Xiaohui Zeng, Arash Vahdat, Francis Williams, Zan Gojcic, Or Litany, Sanja Fidler, and Karsten Kreis. Lion: Latent point diffusion models for 3d shape generation. *arXiv preprint arXiv:2210.06978*, 2022.
- Biao Zhang and Peter Wonka. Functional diffusion. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 4723–4732, 2024.
- Biao Zhang, Matthias Nießner, and Peter Wonka. 3dilg: Irregular latent grids for 3d generative modeling. *Advances in Neural Information Processing Systems*, 35:21871–21885, 2022.

-
- Biao Zhang, Jiapeng Tang, Matthias Nießner, and Peter Wonka. 3dshape2vecset: A 3d shape representation for neural fields and generative diffusion models. *ACM Trans. Graph.*, 42(4), July 2023. ISSN 0730-0301. doi: 10.1145/3592442. URL <https://doi.org/10.1145/3592442>.
- Longwen Zhang, Ziyu Wang, Qixuan Zhang, Qiwei Qiu, Anqi Pang, Haoran Jiang, Wei Yang, Lan Xu, and Jingyi Yu. Clay: A controllable large-scale generative model for creating high-quality 3d assets. *ACM Trans. Graph.*, 43(4), July 2024a. ISSN 0730-0301. doi: 10.1145/3658146. URL <https://doi.org/10.1145/3658146>.
- Longwen Zhang, Ziyu Wang, Qixuan Zhang, Qiwei Qiu, Anqi Pang, Haoran Jiang, Wei Yang, Lan Xu, and Jingyi Yu. Clay: A controllable large-scale generative model for creating high-quality 3d assets. *ACM Transactions on Graphics (TOG)*, 43(4):1–20, 2024b.
- Zibo Zhao, Wen Liu, Xin Chen, Xianfang Zeng, Rui Wang, Pei Cheng, Bin Fu, Tao Chen, Gang Yu, and Shenghua Gao. Michelangelo: Conditional 3d shape generation based on shape-image-text aligned latent representation. *Advances in Neural Information Processing Systems*, 36, 2024.
- Xin-Yang Zheng, Hao Pan, Peng-Shuai Wang, Xin Tong, Yang Liu, and Heung-Yeung Shum. Locally attentional sdf diffusion for controllable 3d shape generation. *ACM Transactions on Graphics (ToG)*, 42(4):1–13, 2023.
- Xin-Yang Zheng, Hao Pan, Yu-Xiao Guo, Xin Tong, and Yang Liu. Mvd²: Efficient multiview 3d reconstruction for multiview diffusion. In *ACM SIGGRAPH 2024 Conference Papers*, pp. 1–11, 2024.
- Qingnan Zhou and Alec Jacobson. Thingi10k: A dataset of 10,000 3d-printing models. *arXiv preprint arXiv:1605.04797*, 2016.

A 数据预处理

数据预处理基于 (Zhang et al., 2022)。

A.1 体积点采样。

我们在包围球内均匀采样体积点。

```
1 N_vol = 250000
2 vol_points = np.random.randn(N_vol, 3)
3 vol_points = vol_points / np.linalg.norm(vol_points, axis=1)[:, None] *
    np.sqrt(3)
4 vol_points = vol_points * np.power(np.random.rand(N_vol), 1./3)[:, None]
```

A.2 近点采样

通过采样高斯抖动的表面点获得近地表点。

```

1 N_near = 125000
2 # surface_points: N_near x 3
3 near_points = [
4     surface_points + np.random.normal(scale=0.005, size=(N_near, 3)),
5     surface_points + np.random.normal(scale=0.05, size=(N_near, 3)),
6 ]
7 near_points = np.concatenate(near_points)

```

B 数据增强

随机轴缩放。 增强来自 (Zhang et al., 2022)。我们为每个轴随机采样一个缩放因子，其值为 $[0.75, 1.25]$ 。

单元球规范化。 我们将每个网格归一化到单位球体，即点云的最大点范数为 1。

```

1 # v: vertices n x 3
2 v = v - (v.max(axis=0) + v.min(axis=0)) / 2
3 distances = np.linalg.norm(v, axis=1)
4 scale = 1 / np.max(distances)
5 v *= scale

```

随机旋转。 我们在训练自编码器时应用随机旋转，

$$\mathbf{R}(\alpha, \beta, \gamma) = \begin{bmatrix} \cos \alpha & -\sin \alpha & 0 \\ \sin \alpha & \cos \alpha & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \cos \beta & 0 & \sin \beta \\ 0 & 1 & 0 \\ -\sin \beta & 0 & \cos \beta \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \gamma & -\sin \gamma \\ 0 & \sin \gamma & \cos \gamma \end{bmatrix}, \quad (13)$$

其中， α 、 β 和 γ 分别表示偏航角、俯仰角和翻滚角。我们的网格首先被规范化的单位球体。因此，在随机旋转之后，模型仍然位于单位球体内。

C 正则化

所提出的正则化（见 Table 2）通过层规范化实现（PyTorch 代码）。

```

1 # network definition
2 self.ftl_proj = nn.Linear(x_dim, z_dim)
3 self.ftl_norm = nn.LayerNorm(dims, elementwise_affine=False, eps=1e-6)
4 # network forward
5 z = self.ftl_norm(self.ftl_proj(x))

```

D 训练时间查询点采样

在先前的工作 (Zhang et al., 2022) 中，训练期间在边界体积内均匀采样 1024 个点。我们发现这种方法在 Objaverse 上效果不佳。由于许多网格具有非常细小的结构，该策略会导致训练过程中无法采样到内部点。这种严重的数据类别不平衡会严重影响占用损失。

我们提出如下解决方案：在每次迭代中，确保一半的点具有正标签，另一半具有负标签。

E 训练损失

损失为二元交叉熵，如先前工作 (Zhang et al., 2022) 所述。形式上，我们有

$$\mathcal{L} = \mathbb{E}_{\mathbf{p} \in \mathbb{R}^3} \left[\text{BCE} \left(\hat{\mathcal{O}}(\mathbf{p}), \mathcal{O}(\mathbf{p}) \right) \right]. \quad (14)$$

实际上，我们使用经验损失

$$\mathbb{E}_{\mathbf{p} \in \mathcal{Q}^{\text{vol}}} \left[\text{BCE} \left(\hat{\mathcal{O}}(\mathbf{p}), \mathcal{O}(\mathbf{p}) \right) \right] + 0.1 \cdot \mathbb{E}_{\mathbf{p} \in \mathcal{Q}^{\text{near}}} \left[\text{BCE} \left(\hat{\mathcal{O}}(\mathbf{p}), \mathcal{O}(\mathbf{p}) \right) \right]. \quad (15)$$

此处， $\mathcal{Q}^{\text{vol}}$ 为体查询点集， $\mathcal{Q}^{\text{near}}$ 为近地表查询点集。

F 扩散

我们使用 EDM (Karras et al., 2022) 来表示扩散模型。推理/采样算法也取自该论文。

G 潜在变量分析

我们分析潜在变量如何影响最终的重构结果。潜在变量部分被标准高斯噪声替换（这是因为我们的潜在变量同样具有零均值和单位方差）。我们在 Fig. 14 中展示了视觉结果。




图 14: 潜在变量显示为红色 z 表示其被高斯噪声替换。潜在变量显示为蓝色 z 表示其通过扩散模型生成。